

Ισιδώρα Δημητρούδη

Ελένη Γεωργούδη

Θρασύβουλος Βασδαβάνος

Βαλεντίνος Γούδας

Νευρωνικά Δίκτυα στην όραση υπολογιστών

ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ
ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ

ABSTRACT

Η παρούσα εργαστηριακή αναφορά ασχολείται με τη χρήση μοντέλων Βαθιάς Μάθησης (Deep Learning) για την επίλυση προβλημάτων ταξινόμησης ψηφιακών εικόνων, μέσα από την ανάπτυξη και συγκριτική αξιολόγηση αρχιτεκτονικών Πλήρως Διασυνδεδεμένων (DNN) και Συνελικτικών (CNN) Νευρωνικών Δικτύων. Στο πρώτο στάδιο της μελέτης, τα μοντέλα σχεδιάστηκαν και εκπαιδεύτηκαν εκ του μηδενός (from scratch) σε ένα σύνολο δεδομένων χειρόγραφων ψηφίων MNIST. Τα πειραματικά αποτελέσματα έδειξαν ότι η αρχιτεκτονική CNN ως προς τη διαχείριση της χωρικής πληροφορίας έβγαλε καλύτερα αποτελέσματα, επιτυγχάνοντας μέση ακρίβεια (Accuracy) προσέγγισης **98.7%**, έναντι **97.7%** του αντίστοιχου DNN.

Στο δεύτερο στάδιο, διερευνήθηκε η δυνατότητα και η αποτελεσματικότητα της τεχνικής Μεταφοράς Μάθησης (Transfer Learning), επιχειρώντας την προσαρμογή των προ-εκπαιδευμένων μοντέλων σε ένα νέο, πιο σύνθετο σύνολο δεδομένων (Fashion-MNIST). Η πειραματική διαδικασία έδειξε ότι η απευθείας μεταφορά γνώσης (βαρών) από τα ψηφία στα είδη ένδυσης παρουσιάζει σημαντικούς περιορισμούς, καθώς τα μοντέλα που εκπαιδεύτηκαν εξαρχής στο Fashion-MNIST σημείωσαν αρκετά καλύτερες επιδόσεις (περίπου **90%** ακρίβεια) σε σχέση με το μοντέλο μεταφοράς μάθησης (περίπου **71-72%** ακρίβεια).

Για τη διασφάλιση της αξιοπιστίας των εξαγόμενων συμπερασμάτων, τη στατιστική εγκυρότητα των μετρικών και την αποφυγή φαινομένων υπερεκπαίδευσης (overfitting), τα πειράματα υλοποιήθηκαν και αξιολογήθηκαν μέσω της μεθοδολογίας Στρατοποιημένης Επαναλαμβανόμενης Επικύρωσης K-Fold (K-Fold Cross Validation) με τη χρήση 6 folds.

ΠΕΡΙΕΧΟΜΕΝΑ

1) ΕΙΣΑΓΩΓΗ
1.1 Παρουσίαση των Συνόλων Δεδομένων..... 1
1.2 Μεθοδολογία Αξιολόγησης..... 2
2) CNN VS DNN
2.1 Θεωρητικό Πλαίσιο Αρχιτεκτονικών..... 5
2.2 Σχεδιασμός και Αρχιτεκτονική Μοντέλων..... 8
.1 Αρχιτεκτονική DNN..... 8
.2 Αρχιτεκτονική CNN..... 11
2.3 Πρωτόκολλο Εκπαίδευσης.....
2.4 Παρουσίαση και Ανάλυση Αποτελεσμάτων..... 13
2.5 Τελικά Συμπεράσματα..... 14
3) TRANSFER LEARNING
3.1 Θεωρητικό Υπόβαθρο & Εκπαίδευση..... 15
.1 Layer Freezing..... 15
.2 Fine Tuning..... 18
3.2 Παρουσίαση Αποτελεσμάτων..... 21
.1 From Scratch VS Transfer Learning..... 22
3.3 Domain Shift Analysis..... 24
3.4 Σταθερότητα Προ-Εκπαιδευμένων Μοντέλων..... 27
4) ΕΝ ΤΩ ΒΑΘΕΙ ΑΝΑΛΥΣΗ
4.1 Confusion Matrix Heatmap..... 33
4.2 Ανάλυση Σφαλμάτων..... 34
5) ΣΥΝΟΨΗ & ΠΡΟΕΚΤΑΣΕΙΣ
5.1 Τελικά Συμπεράσματα..... 35
5.2 Μελλοντική Έρευνα..... 36

1. ΕΙΣΑΓΩΓΗ

Τα τεχνητά νευρωνικά δίκτυα αποτελούν βασικό πυλώνα στον τομέα της Όρασης Υπολογιστών (Computer Vision), καθώς προσφέρουν τη δυνατότητα στα υπολογιστικά συστήματα να αντιλαμβάνονται και να αναλύουν οπτικές πληροφορίες σχεδόν όπως τις προσεγγίζει τη ανθρώπινη όραση. Η ικανότητά τους να αναγνωρίζουν περίπλοκα μοτίβα, να εξάγουν χαρακτηριστικά από τις εικόνες και να αναγνωρίζουν νέα δεδομένα τα καθιστά αναγκαία για

εφαρμογές όπως η αυτόνομη οδήγηση, η ιατρική διάγνωση και η αυτοματοποιημένη ταξινόμηση αντικειμένων.

Η συγκεκριμένη εργαστηριακή αναφορά εστιάζει στην πρακτική υλοποίηση και τη συγκριτική αξιολόγηση των παρακάτω δύο αρχιτεκτονικών, καθώς και στη πρακτική εφαρμογή της Μεταφοράς Μάθησης (Transfer Learning) σε πιο σύνθετα προβλήματα. Στις υποενότητες που ακολουθούν, παρουσιάζονται αναλυτικά τα σύνολα δεδομένων (datasets) που χρησιμοποιήθηκαν για τις ανάγκες των πειραμάτων, αλλά και η μεθοδολογία αξιολόγησης που εφαρμόστηκε για να διασφαλήσουμε τη εγκυρότητα και τη αξιοπιστία των συμπερασμάτων.

1.1 Παρουσίαση των Συνόλων Δεδομένων

Για την υλοποίηση των πειραμάτων και την αξιολόγηση των αρχιτεκτονικών χρησιμοποιήσαμε δύο σύνολα δεδομένων (datasets) με στόχο την επίλυση των δύο ερωτημάτων της εργασίας.

Σύνολο Δεδομένων MNIST: Αποτελείται από 70.000 ασπρόμαυρες εικόνες χειρόγραφων ψηφίων (από το 0 έως το 9) με διάσταση 28x28 pixels. Στο πλαίσιο του πρώτου ερωτήματος, το συγκεκριμένο dataset χρησιμοποιείται για την εκπαίδευση εκ του μηδενός (from scratch) δύο αρχιτεκτονικών: ενός Πλήρως Διασυνδεδεμένου Δικτύου (DNN) και ενός Συνελικτικού Νευρωνικού Δικτύου (CNN). Στόχος μας είναι η αξιολόγηση της απόδοσής τους στην αναγνώριση των ψηφίων και η τελική αποθήκευση των βέλτιστων μοντέλων σε μορφή αρχείων `.h5`.

Σύνολο Δεδομένων Fashion-MNIST: Περιλαμβάνει επίσης 70.000 ασπρόμαυρες εικόνες με διάσταση 28x28 pixels, οι οποίες όμως κατανέμονται σε 10 κατηγορίες που αφορούν είδη ένδυσης και υπόδησης (π.χ. μπλούζες, παντελόνια, φορέματα, παπούτσια). Το συγκεκριμένο dataset φαίνεται να παρουσιάζει μεγαλύτερη πολυπλοκότητα και βαθμό δυσκολίας στην ταξινόμηση σε σχέση με το MNIST. Στο δεύτερο ερώτημα, το συγκεκριμένο dataset χρησιμοποιείται για την αποτίμηση της τεχνικής Μεταφοράς Μάθησης (Transfer Learning), εξετάζοντας αν η γνώση που αποκτήθηκε από το MNIST μπορεί να μεταφερθεί και να εφαρμοστεί αποδοτικά στο Fashion-MNIST, συγκρίνοντας τα αποτελέσματα με μοντέλα που εκπαιδεύονται εξαρχής στο ίδιο σύνολο δεδομένων.

1.2 Παρουσίαση των Αρχιτεκτονικών Νευρωνικών Δικτύων

Η επιλογή της κατάλληλης αρχιτεκτονικής επηρεάζει άμεσα την απόδοση της ταξινόμησης. Στην εργασία αυτή αναλύουμε και συγκρίνουμε δύο διαφορετικές προσεγγίσεις:

Πλήρως Διασυνδεδεμένα Δίκτυα (DNN): Αποτελούνται από επίπεδα πυκνών νευρώνων (Dense Layers). Απαιτούν τη μετατροπή της εικόνας σε μονοδιάστατο διάνυσμα 784 στοιχείων (Flattening), με αποτέλεσμα να χάνεται η χωρική πληροφορία και οι σχέσεις μεταξύ των γειτονικών pixels.

Συνελικτικά Νευρωνικά Δίκτυα (CNN): Σχεδιασμένα ειδικά για εικόνες, χρησιμοποιούν επίπεδα συνέλιξης (Convolutional Layers) με φίλτρα που σαρώνουν την είσοδο. Έτσι, διατηρούν τη χωρική δομή και εντοπίζουν αυτόματα τοπικά χαρακτηριστικά (ακμές, σχήματα), ενώ τα επίπεδα Pooling μειώνουν τις διαστάσεις.

1.3 Μεθοδολογία Αξιολόγησης

Για την εξαγωγή ασφαλών και αντικειμενικών συμπερασμάτων, τη διασφάλιση της σταθερότητας των μοντέλων και την αντιμετώπιση του φαινομένου της υπερεκπαίδευσης (overfitting), σε όλους τους πειραματισμούς εφαρμόσαμε τη μεθοδολογία της **Επαναλαμβανόμενης Επικύρωσης K-Fold (K-Fold Cross Validation)** με τη χρήση 6 folds (6 υποσυνόλων δεδομένων).

Η συγκεκριμένη τεχνική υπόσχεται ότι κάθε δείγμα των datasets χρησιμοποιείται τόσο για την εκπαίδευση όσο και για τη δοκιμή των μοντέλων σε διαφορετικούς κύκλους (folds). Με αυτό τον τρόπο, η αξιολόγηση των δικτύων δεν βασίζεται σε έναν τυχαίο, μεμονωμένο διαχωρισμό των δεδομένων. Αντίθετα, οι τελικές επιδόσεις και η ικανότητα των αρχιτεκτονικών προκύπτουν από τον υπολογισμό των μέσων όρων και των τυπικών αποκλίσεων των βασικών μετρικών αξιολόγησης, οι οποίες είναι η Ακρίβεια (Accuracy), η Πιστότητα (Precision), η Ανάκληση (Recall) και το F1-Score, κατά τη διάρκεια των 6 πειραματικών κύκλων.

2. CNN vs DNN

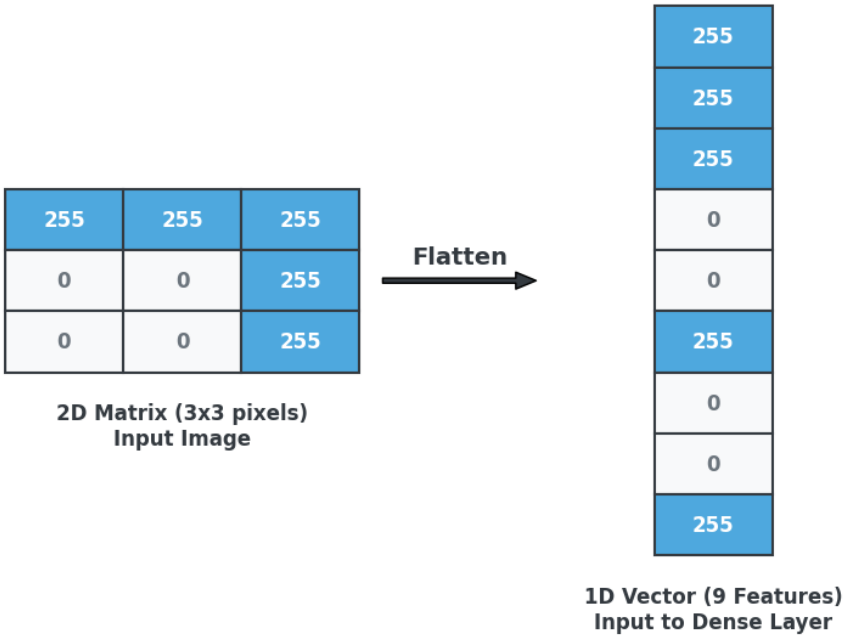
Στην ενότητα αυτή μπαίνουμε στο κυρίως θέμα της εργασίας μας, που δεν είναι άλλο από τη σύγκριση των DNN με τα CNN. Στόχος μας είναι να δούμε ποια από τις δύο αρχιτεκτονικές αποδίδει καλύτερα όταν πρόκειται να αναγνωρίσει εικόνες. Για να γίνει αυτό, θα ξεκινήσουμε περιγράφοντας αναλυτικά τα μοντέλα που σχεδιάσαμε. Η ενότητα ολοκληρώνεται με την

παρουσίαση των πειραματικών αποτελεσμάτων μας πάνω στο σύνολο δεδομένων MNIST, όπου και θα φανεί αν η θεωρητική υπεροχή της μίας τεχνικής επιβεβαιώνεται από τα νούμερα και τις μετρικές.

2.1 Θεωρητικό Πλαίσιο Αρχιτεκτονικών

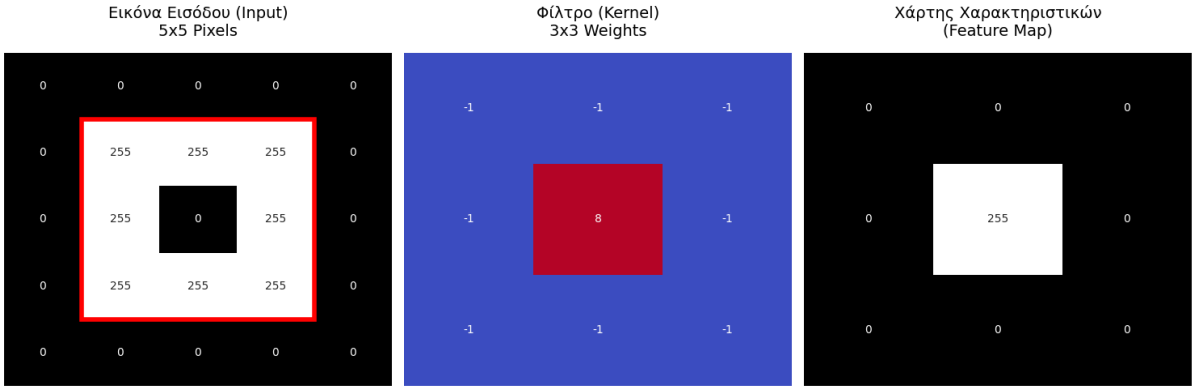
Πριν προχωρήσουμε στην παρουσίαση των αριθμητικών δεδομένων και του κώδικα, κρίνουμε σκόπιμο να αναλύσουμε τη θεωρητική βάση των εργαλείων που χρησιμοποιήσαμε. Η επιτυχία της ταξινόμησης εξαρτάται από τον τρόπο με τον οποίο το κάθε δίκτυο επεξεργάζεται την εικόνα. Αυτή είναι και η κύρια διαφορά μεταξύ των DNN και των CNN.

Στην περίπτωση των Πλήρως Διασυνδεδεμένων Δικτύων (DNN), η επεξεργασία ξεκινά πάντα με την ισοπέδωση (flattening) των δεδομένων. Για τις εικόνες του MNIST, αυτό σημαίνει ότι μετατρέπουμε τον πίνακα των 28x28 pixels σε ένα μονοδιάστατο διάνυσμα 784 στοιχείων. Με αυτόν τον τρόπο, κάθε pixel τροφοδοτείται στο δίκτυο ως μια αυτόνομη είσοδος, αποσυνδεδεμένη από τα γειτονικά της. Το πρόβλημα που εντοπίζουμε εδώ είναι η απώλεια της χωρικής πληροφορίας: το δίκτυο σταματά να εντοπίζει τη γεωμετρία που σχηματίζουν τα pixels (π.χ. μια καμπύλη ή μια γωνία), γεγονός που καθιστά το μοντέλο λιγότερο ανθεκτικό σε αλλαγές θέσης ή μικρές παραμορφώσεις του ψηφίου.



"Σχηματική αναπαράσταση της διαδικασίας Flattening και της απώλειας της χωρικής γειτνίασης"

Αντιθέτως, στα CNN ακολουθήσαμε μια προσέγγιση που κρατάει τη δισδιάστατη δομή της εικόνας. Αντί να ισοπεδώσουμε, όπως κάναμε στο DNN, την πληροφορία, χρησιμοποιήσαμε συνελικτικά φίλτρα (convolutional layers) τα οποία σαρώνουν την εικόνα τοπικά. Αυτή η διαδικασία μας επιτρέπει να εντοπίζουμε χωρικά χαρακτηριστικά, όπως ακμές και βασικά σχήματα, διατηρώντας τη συσχέτιση των γειτονικών pixels. Αυτή η ικανότητα κάνει τα CNN ιδανικά για προβλήματα όρασης υπολογιστών, καθώς μαθαίνουν να αναγνωρίζουν οπτικά πρότυπα ανεξάρτητα από το πού ακριβώς βρίσκονται, κάτι που θα δούμε να επιβεβαιώνεται και από τις καλύτερες τιμές τους στα πειραματικά μας αποτελέσματα.



"Λειτουργία συνελικτικών φίλτρων για την εξαγωγή τοπικών χαρακτηριστικών"

2.2 Σχεδιασμός και Αρχιτεκτονική Μοντέλων

Σε αυτό το σημείο της αναφοράς, προχωράμε στην αναλυτική παρουσίαση των δύο μοντέλων που σχεδιάσαμε και εκπαιδεύσαμε. Η δομή τους βασίστηκε στις προδιαγραφές της εκφώνησης, με στόχο τη δημιουργία ισχυρών μοντέλων που να μπορούν να γενικεύουν σωστά σε άγνωστα δεδομένα.

2.2.1 Αρχιτεκτονική Πλήρως Διασυνδεδεμένου Δικτύου (DNN)

Το Πλήρως Διασυνδεδεμένο Δίκτυο που υλοποιήσαμε ακολουθεί τη φιλοσοφία ενός πολυστρωματικού perceptron (MLP). Καθώς οι εικόνες εισόδου έχουν διαστάσεις 28x28, το πρώτο επίπεδο της αρχιτεκτονικής μας είναι ένα επίπεδο ισοπέδωσης (Flatten). Η λειτουργία του είναι να μετασχηματίζει τον δισδιάστατο πίνακα της εικόνας σε ένα μονοδιάστατο διάνυσμα 784 χαρακτηριστικών, επιτρέποντας στην πληροφορία να περάσει στα επόμενα επίπεδα.

Στη συνέχεια, τοποθετήσαμε πλήρως διασυνδεδεμένα επίπεδα (Dense layers). Στο μοντέλο μας, επιλέξαμε να χρησιμοποιήσουμε δύο κρυφά επίπεδα με 128 και 64 νευρώνες αντίστοιχα, ενώ ως συνάρτηση ενεργοποίησης σε όλα τα κρυφά επίπεδα ορίσαμε τη ReLU (Rectified Linear Unit). Η επιλογή της ReLU έγινε με σκοπό την αποφυγή του προβλήματος της εξαφάνισης της κλίσης (vanishing gradient) και την επίτευξη ταχύτερης σύγκλισης κατά την εκπαίδευση.

Προκειμένου να προστατεύσουμε το μοντέλο από το φαινόμενο της υπερεκπαίδευσης (overfitting) και να μην επιτρέψουμε στο δίκτυο να

«απομνημονεύσει» τα δεδομένα, ενσωματώσαμε ένα επίπεδο Dropout με ρυθμό αποκοπής 0.5. Η τεχνική αυτή απενεργοποιεί τυχαία τους μισούς νευρώνες σε κάθε επανάληψη, αναγκάζοντας το δίκτυο να αναπτύξει πιο στιβαρές αναπαραστάσεις των δεδομένων.

Τέλος, η αρχιτεκτονική μας ολοκληρώνεται με το επίπεδο εξόδου, το οποίο αποτελείται από 10 νευρώνες, αντιστοιχώντας στις κλάσεις των ψηφίων (0-9). Εκεί εφαρμόσαμε τη συνάρτηση ενεργοποίησης Softmax, η οποία μετατρέπει τις εξόδους σε πιθανότητες, επιτρέποντάς μας να ταξινομήσουμε την εικόνα στην επικρατέστερη κλάση.



"Σχηματική απεικόνιση της αρχιτεκτονικής του προτεινόμενου DNN"

Παρακάτω συνοψίζεται ο αριθμός των εκπαιδεύσιμων παραμέτρων του μοντέλου:

```
Total params: 109,386 (427.29 KB)
Trainable params: 109,386 (427.29 KB)
Non-trainable params: 0 (0.00 B)
```

2.2.2 Αρχιτεκτονική Συνελικτικού Νευρωνικού Δικτύου (CNN)

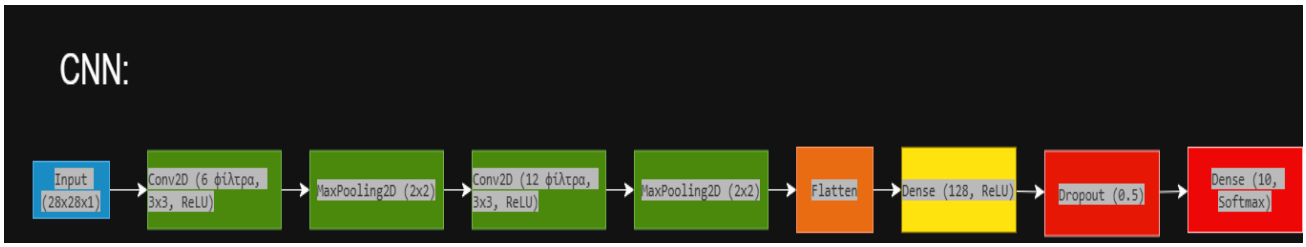
Σε αντίθεση με το DNN, για τον σχεδιασμό του Συνελικτικού Νευρωνικού Δικτύου (CNN) εστιάσαμε στην εκμετάλλευση και διατήρηση της δισδιάστατης χωρικής δομής των εικόνων. Η αρχιτεκτονική που υλοποιήσαμε βασίζεται στην εναλλαγή επιπέδων συνέλιξης και υποδειγματοληψίας, επιτρέποντας στο μοντέλο να «μαθαίνει» με ιεραρχικό τρόπο, τα χαρακτηριστικά των ψηφίων.

Η εξαγωγή των χαρακτηριστικών επιτυγχάνεται μέσω δύο συνελικτικών επιπέδων (Conv2D). Στο πρώτο επίπεδο εφαρμόσαμε 6 φίλτρα και στο δεύτερο 12 φίλτρα, και στις δύο περιπτώσεις με πυρήνα μεγέθους 3x3 (kernel size). Τα

επίπεδα αυτά σαρώνουν την εικόνα για να εντοπίσουν χωρικά μοτίβα, όπως ακμές και γωνίες, ενώ χρησιμοποιήσαμε τη συνάρτηση ενεργοποίησης ReLU για την εισαγωγή μη-γραμμικότητας.

Κάθε συνελικτικό επίπεδο ακολουθείται από ένα επίπεδο μέγιστης υποδειγματοληψίας (MaxPooling2D, μεγέθους 2x2). Η λειτουργία αυτή μειώνει τις χωρικές διαστάσεις των χαρτών χαρακτηριστικών (feature maps), διατηρώντας μόνο την πιο έντονη πληροφορία. Με αυτόν τον τρόπο, πετυχαίνουμε σημαντική μείωση του υπολογιστικού κόστους και κάνουμε το μοντέλο πιο ανθεκτικό σε μικρές μετατοπίσεις ή παραμορφώσεις της εισόδου.

Αφού ολοκληρωθεί η εξαγωγή των χωρικών χαρακτηριστικών, τα δεδομένα εξομαλύνονται μέσω ενός επιπέδου Flatten και τροφοδοτούνται στο τμήμα της ταξινόμησης. Αυτό αποτελείται από ένα πλήρως διασυνδεδεμένο επίπεδο (Dense) με 128 νευρώνες. Όπως και στο DNN, πριν το τελικό επίπεδο εξόδου εφαρμόσαμε την τεχνική Dropout (με ρυθμό 0.5) για την ενίσχυση της ικανότητας γενίκευσης του μοντέλου. Τέλος, η αρχιτεκτονική μας ολοκληρώνεται με το επίπεδο εξόδου των 10 νευρώνων με συνάρτηση ενεργοποίησης Softmax.



«Σχηματική αναπαράσταση της αρχιτεκτονικής του CNN με εναλλαγή συνελικτικών επιπέδων και επιπέδων υποδειγματοληψίας»

Παρακάτω συνοψίζεται ο αριθμός των εκπαιδεύσιμων παραμέτρων του μοντέλου:

```
Total params: 40,538 (158.35 KB)
Trainable params: 40,538 (158.35 KB)
Non-trainable params: 0 (0.00 B)
```

Είναι αξιοσημείωτο ότι, αν και το CNN διαθέτει σημαντικά λιγότερες παραμέτρους σε σύγκριση με το DNN (περίπου 40 χιλιάδες έναντι 109 χιλιάδων), η ικανότητά του να αντιλαμβάνεται τη χωρική δομή της εικόνας το καθιστά πολύ πιο έξυπνο και αποδοτικό, καθώς πετυχαίνει υψηλότερη ακρίβεια με πολύ μικρότερο υπολογιστικό όγκο.

2.3 Πρωτόκολλο Εκπαίδευσης και Αξιολόγησης

Προκειμένου να διασφαλίσουμε μια συγκρίσιμη αξιολόγηση των δύο αρχιτεκτονικών (DNN και CNN), εφαρμόσαμε ένα κοινό και αυστηρό πρωτόκολλο εκπαίδευσης. Η μεθοδολογία μας σχεδιάστηκε έτσι ώστε να εγγυάται τη σταθερότητα των μοντέλων και την αξιοπιστία των μετρήσεων που λάβαμε.

- **Συνάρτηση Κόστους και Βελτιστοποίηση:**

Και τα δύο μοντέλα μεταγλωττίστηκαν (compiled) χρησιμοποιώντας τη συνάρτηση απώλειας Categorical Crossentropy, η οποία αποτελεί την ενδεδειγμένη επιλογή για προβλήματα πολυκλασικής ταξινόμησης, όπως η αναγνώριση χειρόγραφων ψηφίων. Για την ανανέωση των βαρών των δικτύων, επιλέξαμε τον αλγόριθμο βελτιστοποίησης Adam, ο οποίος εξασφαλίζει ταχεία σύγκλιση και ομαλή μείωση του σφάλματος.

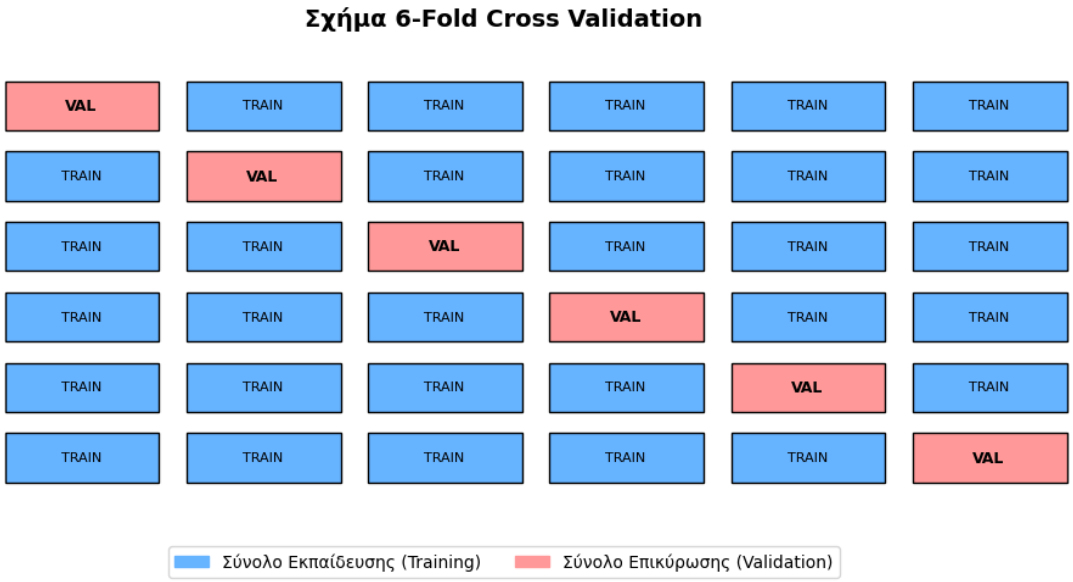
- **Υπερπαράμετροι (Hyperparameters):**

Η διαδικασία της εκπαίδευσης ορίστηκε στις 10 εποχές (epochs) για κάθε κύκλο, ενώ το μέγεθος της παρτίδας (batch size) καθορίστηκε στα 125 δείγματα. Η επιλογή αυτή έγινε με στόχο την ισορροπία μεταξύ της ταχύτητας εκπαίδευσης και της σταθερότητας της καμπύλης απώλειας, αποφεύγοντας τις έντονες διακυμάνσεις κατά τη διάρκεια της μάθησης.

- **Στρατηγική Αξιολόγησης (6-Fold Cross Validation):**

Αντί για έναν στατικό διαχωρισμό των δεδομένων, εφαρμόσαμε τη μέθοδο της Στρωματοποιημένης Διασταυρούμενης Επικύρωσης (Stratified K-Fold Cross Validation) με K=6 πτυχές.

Με αυτή την προσέγγιση, το σύνολο εκπαίδευσης χωρίστηκε σε 6 ίσα τμήματα και η διαδικασία επαναλήφθηκε 6 φορές. Σε κάθε επανάληψη, χρησιμοποιήσαμε τα 5 τμήματα για την εκπαίδευση και το 1 τμήμα ως Σύνολο Επικύρωσης (Validation Set). Αυτό μας επέτρεψε να παρακολουθούμε την απόδοση του μοντέλου και το φαινόμενο της υπερεκπαίδευσης (overfitting) σε πραγματικό χρόνο μέσω των καμπυλών απώλειας.

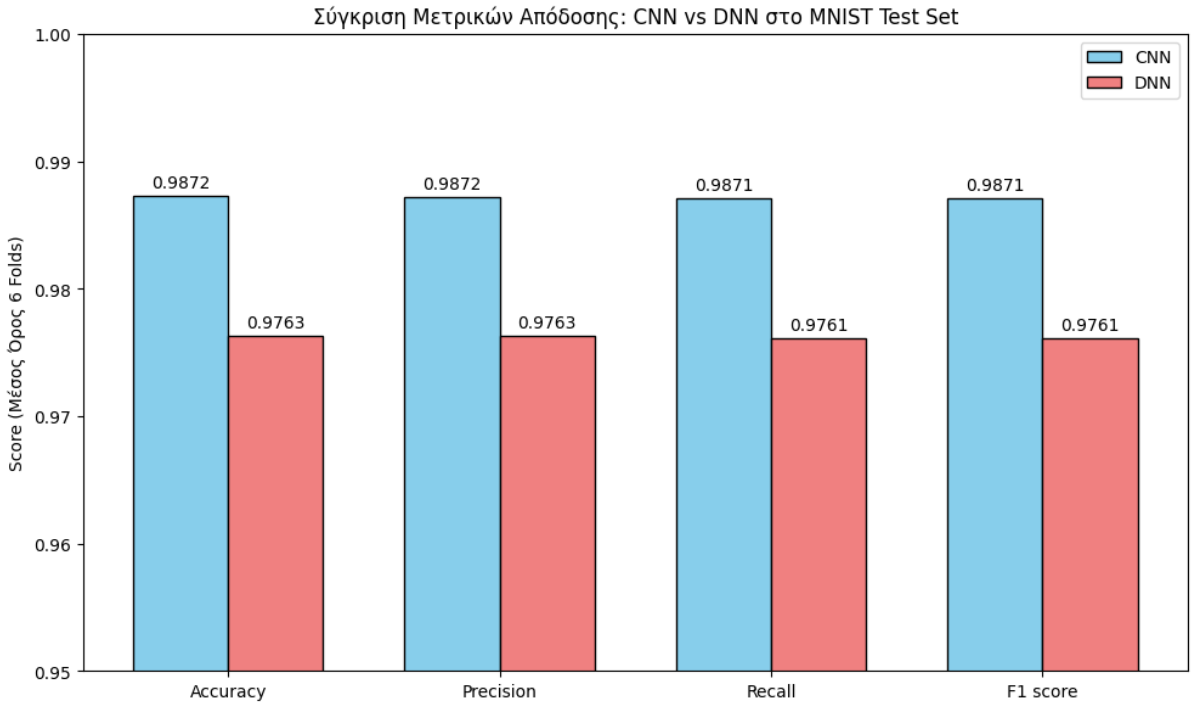


"Απεικόνιση της διαδικασίας 6-Fold Cross Validation για την αξιολόγηση της γενίκευσης των μοντέλων"

Η τελική μέτρηση των επιδόσεων των μοντέλων πραγματοποιήθηκε στο ανεξάρτητο σύνολο ελέγχου (Test Set) των 10.000 εικόνων. Τα τελικά αποτελέσματα που παρουσιάζουμε στην επόμενη ενότητα προκύπτουν από τον μέσο όρο (average) των 6 ανεξάρτητων εκπαιδεύσεων, διασφαλίζοντας έτσι ότι οι μετρήσεις μας δεν είναι τυχαίες αλλά αντιπροσωπευτικές της πραγματικής ικανότητας των δικτύων.

2.4 Παρουσίαση και Ανάλυση Αποτελεσμάτων

Η πειραματική διαδικασία απέφερε δεδομένα, που επιτρέπουν μια σε βάθος σύγκριση της συμπεριφοράς και της αποδοτικότητας των δύο αρχιτεκτονικών. Όπως προαναφέρθηκε στο πρωτόκολλο εκπαίδευσης, όλες οι μετρήσεις που παρατίθενται προκύπτουν από τον μέσο όρο των 6 ανεξάρτητων κύκλων (folds), γεγονός που θωρακίζει τα συμπεράσματά μας έναντι τυχαίων παραγόντων ή ευνοϊκών διαχωρισμών των δεδομένων.



Η πρώτη και πιο προφανής παρατήρηση αφορά τη σαφή και σταθερή υπεροχή του Συνελικτικού Νευρωνικού Δικτύου (CNN) έναντι του Πλήρως Διασυνδεδεμένου Δικτύου (DNN). Το CNN πέτυχε μέση ακρίβεια στο σύνολο ελέγχου της τάξης του 98.72%, σημειώνοντας κορυφαίες επιδόσεις σε όλες τις επιμέρους μετρικές (Precision: 98.72%, Recall: 98.71%, F1-score: 98.71%). Η επίδοση αυτή είναι ιδιαίτερα αξιοσημείωτη αν αναλογιστεί κανείς ότι επιτυγχάνεται με λιγότερο από το μισό αριθμό εκπαιδεύσιμων παραμέτρων σε σχέση με το DNN, αποδεικνύοντας την υψηλή υπολογιστική του αποδοτικότητα.

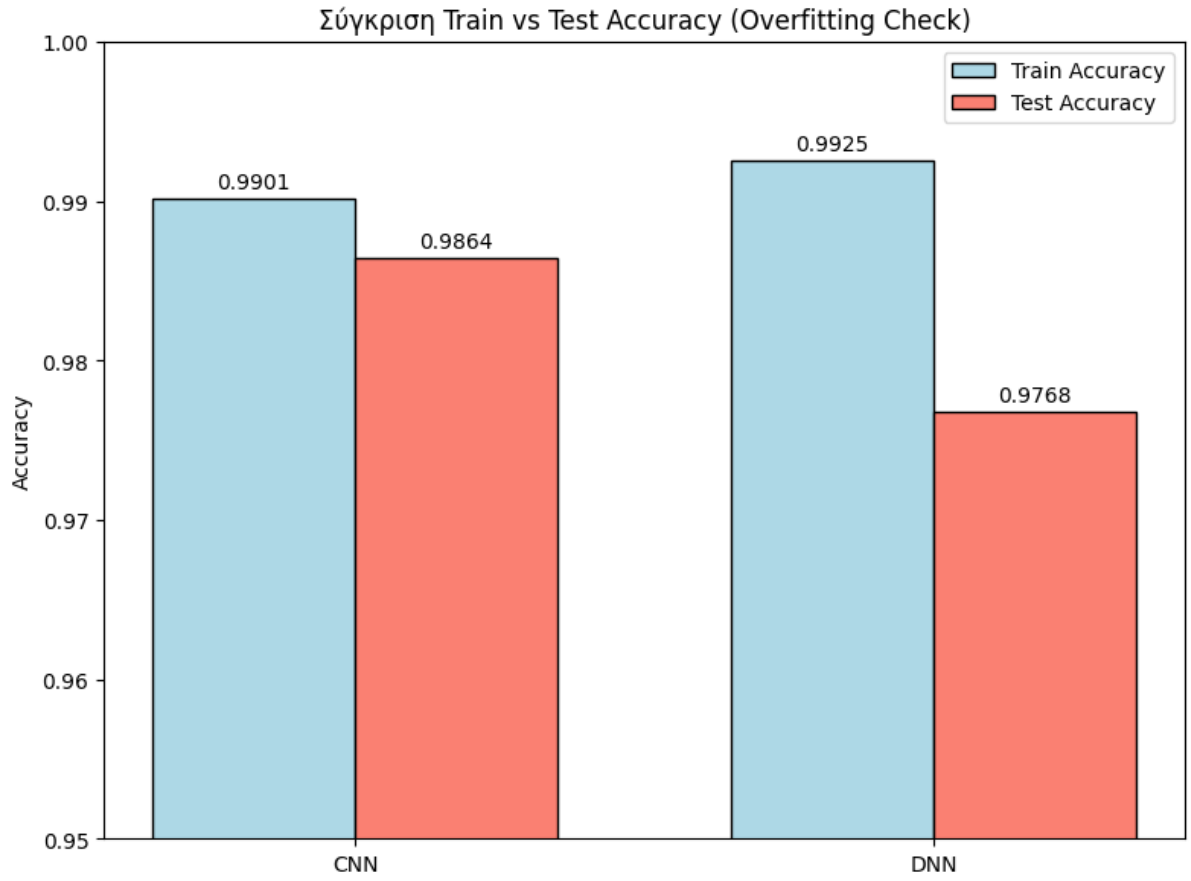
Η πρώτη και πιο προφανής παρατήρηση αφορά τη σαφή και σταθερή υπεροχή του Συνελικτικού Νευρωνικού Δικτύου (CNN) έναντι του Πλήρως Διασυνδεδεμένου Δικτύου (DNN). Το CNN πέτυχε μέση ακρίβεια στο σύνολο ελέγχου της τάξης του 98.72%, σημειώνοντας κορυφαίες επιδόσεις σε όλες τις επιμέρους μετρικές (Precision: 98.72%, Recall: 98.71%, F1-score: 98.71%). Η επίδοση αυτή είναι ιδιαίτερα αξιοσημείωτη αν αναλογιστεί κανείς ότι επιτυγχάνεται με λιγότερο από το μισό αριθμό εκπαιδεύσιμων παραμέτρων σε σχέση με το DNN, αποδεικνύοντας την υψηλή υπολογιστική του αποδοτικότητα.

Αναλύοντας τη συμπεριφορά του DNN, εντοπίζουμε μια αξιοσημείωτη «ψαλίδα» μεταξύ της απόδοσης στο σύνολο εκπαίδευσης (99.25%) και στο σύνολο ελέγχου (97.63%). Αυτή η απόκλιση του 1.62% αποτελεί σαφή ένδειξη ότι το μοντέλο παρουσιάζει τάσεις υπερ-προσαρμόσματος (overfitting). Η αρχιτεκτονική του DNN, αντιμετωπίζοντας κάθε pixel ως μια ανεξάρτητη

μεταβλητή, αναγκάζει το δίκτυο να αναζητά σύνθετους συνδυασμούς μεμονωμένων τιμών για την ταξινόμηση, οδηγώντας συχνά στην απομνημόνευση θορύβου του dataset αντί για την εκμάθηση των δομικών χαρακτηριστικών των ψηφίων.

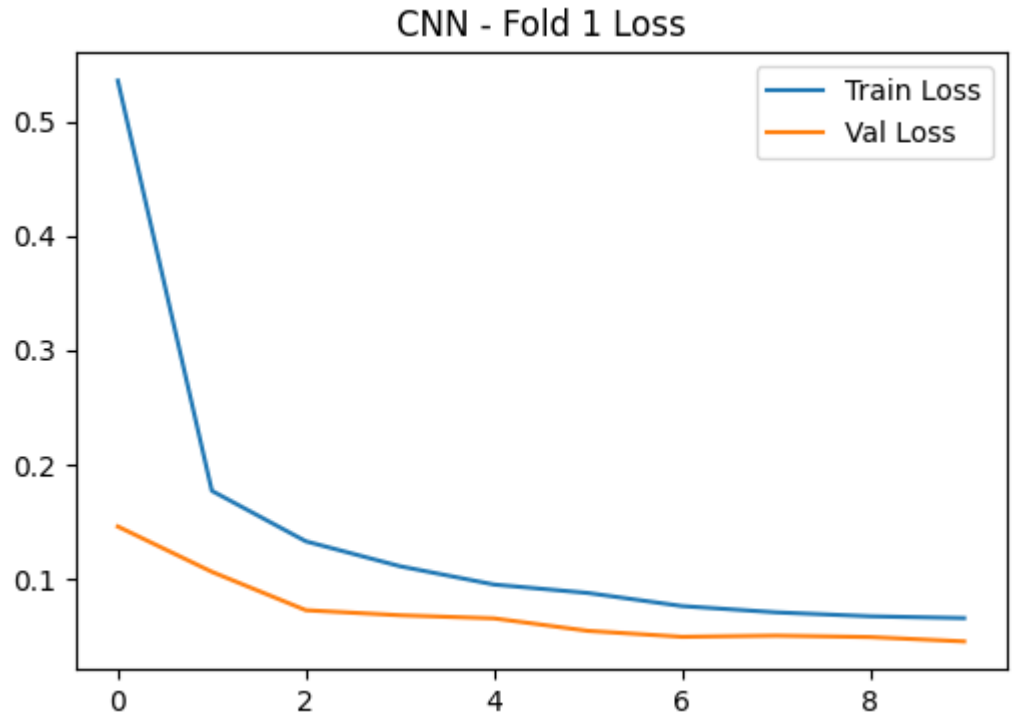
Στον αντίποδα, το CNN επιδεικνύει μια εξαιρετικά στιβαρή συμπεριφορά, με τη διαφορά μεταξύ Train και Test Accuracy να περιορίζεται μόλις στο 0.29% (99.01% έναντι 98.72%). Η σταθερότητα αυτή υποδηλώνει ότι το μοντέλο έχει αναπτύξει μια «ανθεκτική» αντίληψη των οπτικών προτύπων. Λόγω της συνελικτικής του φύσης, το δίκτυο εστιάζει σε τοπικές δομές (όπως ακμές, καμπύλες και γωνίες) οι οποίες παραμένουν αναλλοίωτες ανεξάρτητα από μικρές μετατοπίσεις ή παραμορφώσεις του ψηφίου μέσα στο κάδρο, εξασφαλίζοντας έτσι κορυφαία ικανότητα γενίκευσης.

Στον αντίποδα, το CNN επιδεικνύει μια εξαιρετικά στιβαρή συμπεριφορά, με τη διαφορά μεταξύ Train και Test Accuracy να περιορίζεται μόλις στο 0.29% (99.01% έναντι 98.72%). Η σταθερότητα αυτή υποδηλώνει ότι το μοντέλο έχει αναπτύξει μια «ανθεκτική» αντίληψη των οπτικών προτύπων. Λόγω της συνελικτικής του φύσης, το δίκτυο εστιάζει σε τοπικές δομές (όπως ακμές, καμπύλες και γωνίες) οι οποίες παραμένουν αναλλοίωτες ανεξάρτητα από μικρές μετατοπίσεις ή παραμορφώσεις του ψηφίου μέσα στο κάδρο, εξασφαλίζοντας έτσι κορυφαία ικανότητα γενίκευσης.



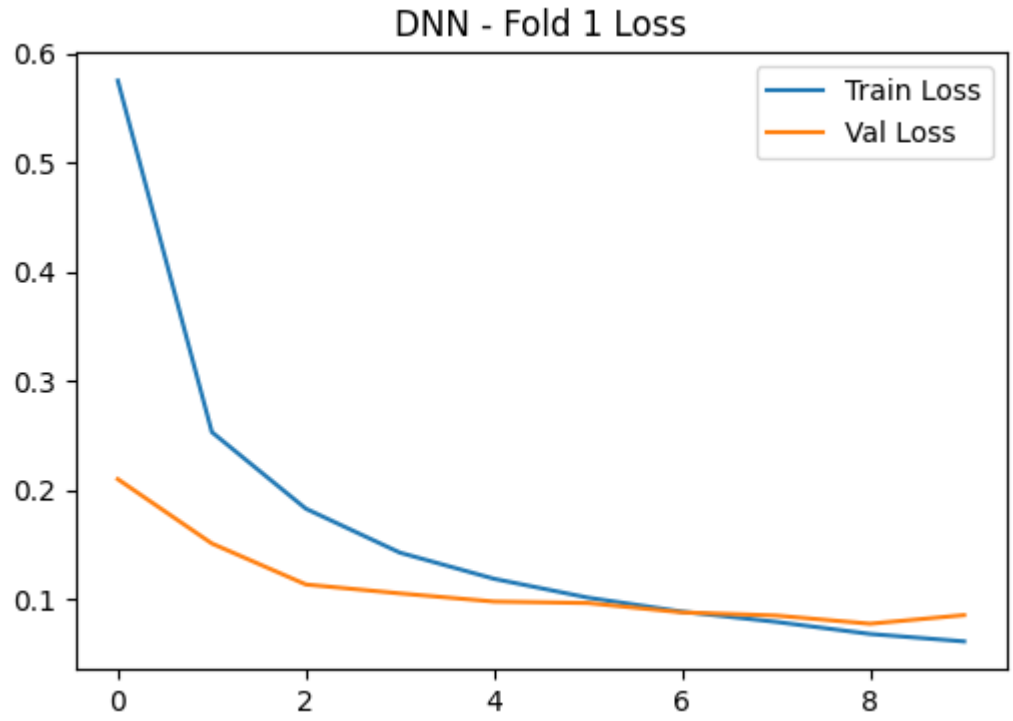
Ανάλυση Καμπυλών Απώλειας (Loss Curves)

Η παραπάνω ανάλυση επιβεβαιώνεται με τον πλέον παραστατικό τρόπο από τις καμπύλες απώλειας (Loss Curves), όπως αυτές αποτυπώθηκαν κατά την εκτέλεση του Fold 1.



"Σύγκριση καμπυλών απώλειας (Training vs Validation Loss) για τις δύο αρχιτεκτονικές"

Η εικόνα του CNN αποπνέει σταθερότητα. Οι δύο καμπύλες ακολουθούν μια παράλληλη πτωτική πορεία, παραμένοντας πολύ κοντά η μία στην άλλη μέχρι την τελευταία εποχή. Είναι ενδιαφέρον να σημειώθεί ότι η απώλεια επικύρωσης (0.052) παραμένει συστηματικά χαμηλότερη από την απώλεια εκπαίδευσης (0.071). Το φαινόμενο αυτό οφείλεται στην εφαρμογή της τεχνικής Dropout (0.5) κατά την εκπαίδευση. Το Dropout δυσκολεύει το δίκτυο να ταξινομήσει σωστά τις εικόνες εκπαίδευσης απενεργοποιώντας τυχαία τους μισούς νευρώνες, γεγονός που αυξάνει τεχνητά το Training Loss. Ωστόσο, κατά τη φάση της επικύρωσης, όλοι οι νευρώνες είναι ενεργοί και το δίκτυο αποδίδει εξαιρετικά.



"Σύγκριση καμπυλών απώλειας (Training vs Validation Loss) για τις δύο αρχιτεκτονικές"

Αντίθετα, στο διάγραμμα του DNN, η απόκλιση μεταξύ των καμπυλών Training Loss και Validation Loss είναι ευκρινής. Ενώ η απώλεια εκπαίδευσης μειώνεται σταθερά προς το 0.065, η καμπύλη επικύρωσης (Validation) σταματά να βελτιώνεται μετά τις πρώτες εποχές και παραμένει σε υψηλότερα επίπεδα (0.081), παρουσιάζοντας μάλιστα μια ελαφρά αυξητική τάση στο τέλος. Αυτό το «κενό» μεταξύ των δύο καμπυλών είναι η οπτική επιβεβαίωση του overfitting: το δίκτυο συνεχίζει να βελτιώνεται πάνω στα δεδομένα που ήδη γνωρίζει, αλλά χάνει σταδιακά την επαφή του με την πραγματική κατανομή των άγνωστων δεδομένων.

Συνοψίζοντας, η πειραματική ανάλυση αναδεικνύει το CNN ως τον αδιαμφισβήτητο «νικητή» της σύγκρισης. Η ικανότητά του να επιτυγχάνει ανώτερη ακρίβεια με σημαντικά λιγότερους υπολογιστικούς πόρους και, κυρίως, η ανθεκτικότητά του απέναντι στο φαινόμενο της υπερεκπαίδευσης, το καθιστούν τη βέλτιστη επιλογή για προβλήματα όρασης υπολογιστών.

2.5 Τελικά Συμπεράσματα

Μετά από όλη αυτή τη συγκριτική ανάλυση, το βασικό συμπέρασμα για εμάς είναι ένα: το CNN παίζει σε εντελώς άλλη κατηγορία όταν πρόκειται για

επεξεργασία εικόνας. Αυτό που μας έκανε τη μεγαλύτερη εντύπωση είναι ότι, παρόλο που το DNN είχε έναν τεράστιο αριθμό παραμέτρων για να «δουλέψει», τελικά δεν κατάφερε να ξεπεράσει το CNN. Αντίθετα, φάνηκε ότι το DNN περιορίστηκε στο να απομνημονεύει τα δεδομένα εκπαίδευσης, κάτι που οδήγησε στο αναμενόμενο overfitting και σε ένα χαμηλότερο accuracy στο test set (97.63%).

Στην ουσία, τα αποτελέσματα επιβεβαίωσαν τη θεωρία που λέγαμε στην αρχή. Όταν επιλέγουμε να κάνουμε flattening σε μια εικόνα, στην πραγματικότητα πετάμε όλη τη χωρική πληροφορία που την κάνει αναγνωρίσιμη. Το CNN όμως, χάρη στα φίλτρα και τη δομή του, κατάφερε να «δει» τα σχήματα των ψηφίων όπως είναι στην πραγματικότητα, χωρίς να χάνει τη συνοχή τους. Έτσι έφτασε στο 98.72% πολύ πιο ξεκούραστα και σταθερά. Για την ομάδα μας, η υπεροχή του CNN δεν είναι απλώς ένα θέμα αριθμών, αλλά θέμα σωστής αρχιτεκτονικής. Είναι το μόνο μοντέλο που μπορεί να εγγυηθεί αξιοπιστία και σωστή γενίκευση σε τέτοιου είδους προβλήματα.

3. TRANSFER LEARNING

Έχοντας ολοκληρώσει την συγκριτική αξιολόγηση των βασικών αρχιτεκτονικών, το παρόν κεφάλαιο εστιάζει στην διερεύνηση της στρατηγικής της Μεταφοράς Μάθησης (Transfer Learning). Το κύριο ζητούμενο, είναι να εξεταστεί εάν η "οπτική γνώση" που απέκτησαν τα προ-εκπαιδευμένα μοντέλα (CNN και DNN) μπορεί να επαναχρησιμοποιηθεί εξίσου αποτελεσματικά σε πολυπλοκότερα προβλήματα - συγκεκριμένα την ταξινόμηση ποικίλων ειδών ένδυσης του συνόλου δεδομένων Fashion MNIST.

3.1 Θεωρητικό Υπόβαθρο & Εκπαίδευση

Για να γίνει κατανοητή η στρατηγική του Transfer Learning θα πρέπει να αναλογιστούμε πως "αναγνωρίζουν" τα δύο μοντέλα ως αυτό το σημείο. Όπως προαναφέρθηκε , ειδικά στην περίπτωση του συνελικτικού δικτύου, τα πρώτα επίπεδα μαθαίνουν να εντοπίζουν πολύ βασικά πράγματα (οριζόντιες γραμμές, κάθετες ακμές, γωνίες). Τα τελευταία επίπεδα συνδυάζουν αυτήν την πληροφορία ώστε να ταξινομήσουν την εικόνα σε κατάλληλη κλάση - αριθμό. Παραδείγματος χάρη: "Δύο κύκλοι ο ένας πάνω στον άλλον δηλώνουν τον αριθμό 8".

Περνώντας σε ένα πιο πολύπλοκο φάσμα δεδομένων όπως το fashion MNIST, αρχικά μεταβάλλεται το περιεχόμενο των κλάσεων. Από τα 0-9 ψηφία που είχαμε

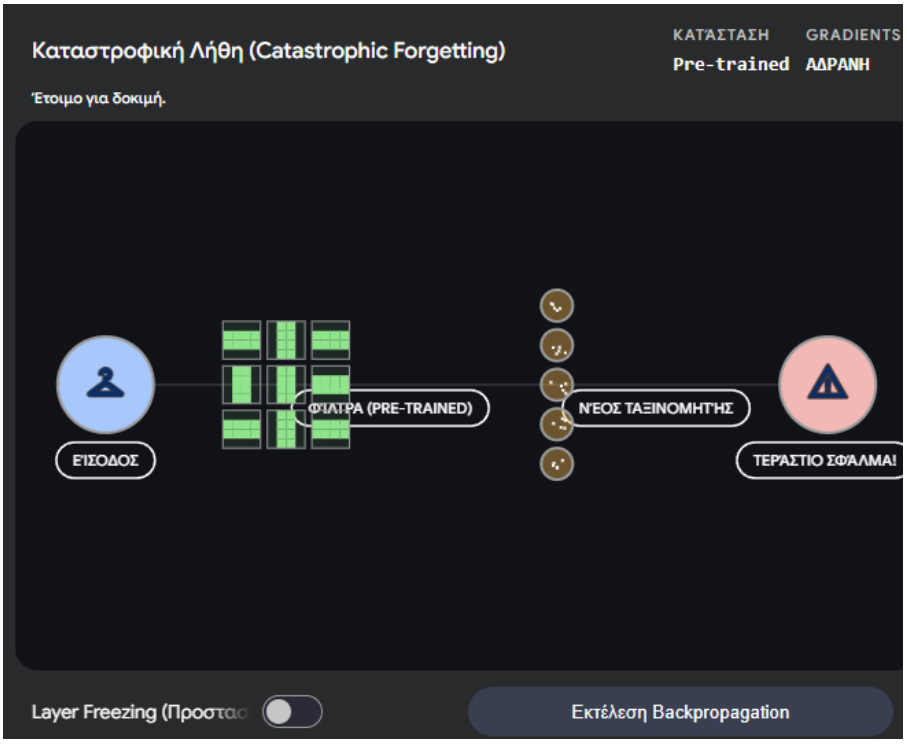
προηγουμένως , πλέον τα μοντέλα καλούνται να χειριστούν "μπουφάν", "πουκάμισο" , "t-shirt" , "παντελόνι".

Σε αυτήν την προσπάθεια δημιουργείται η εξής απειλή: Ενώ τα μοντέλα ενδεχομένως να μπορούν να εντοπίσουν τις καμπύλες που σχηματίζουν τα κουμπιά ενός πουκαμίσου για παράδειγμα, δεν έχουν εκπαιδευτεί να εξάγουν το συμπέρασμα πως το συγκεκριμένο μοτίβο παραπέμπει στην κλάση "πουκάμισο".

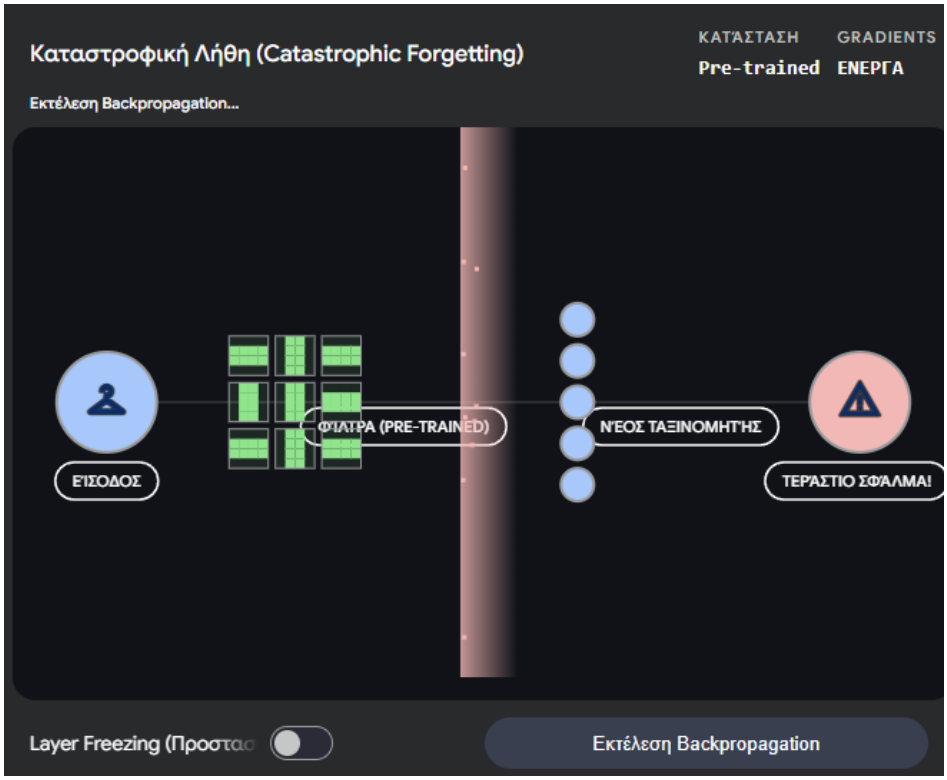
Έχοντας εισάγει τις νέες κλάσεις των ενδυμασιών και χωρίς πλέον να υπάρχουν ψηφία, ο κώδικας θέτει "τυχαία βάρη" για αυτές κατά την δημιουργία του νέου ταξινομητή (νέο Dense Layer).

Με άλλα λόγια, στην πρώτη εποχή, οι προβλέψεις του δικτύου είναι ουσιαστικά τυχαίες μαντεψιές. Οι καμπύλες ενός κουμπιού σε ένα πουκάμισο μπορεί τυχαία να παραπέμψουν σε "παπούτσι". Με αυτόν τον τρόπο η συνάρτηση σφάλματος επιστρέφει τεράστιο αρχικό σφάλμα, του οποίου η ευθύνη λανθασμένα επιρρίπτεται στην ικανότητα του μοντέλου να αναγνωρίζει τις καμπύλες - πράγμα που δεν ήταν προβληματικό. Το δίκτυο καταλήγει να "ξεχνάει" τα βασικά σχήματα και τα μοτίβα που ήξερε, οδηγώντας στο φαινόμενο της Καταστροφικής Λήθης (Catastrophic Forgetting).

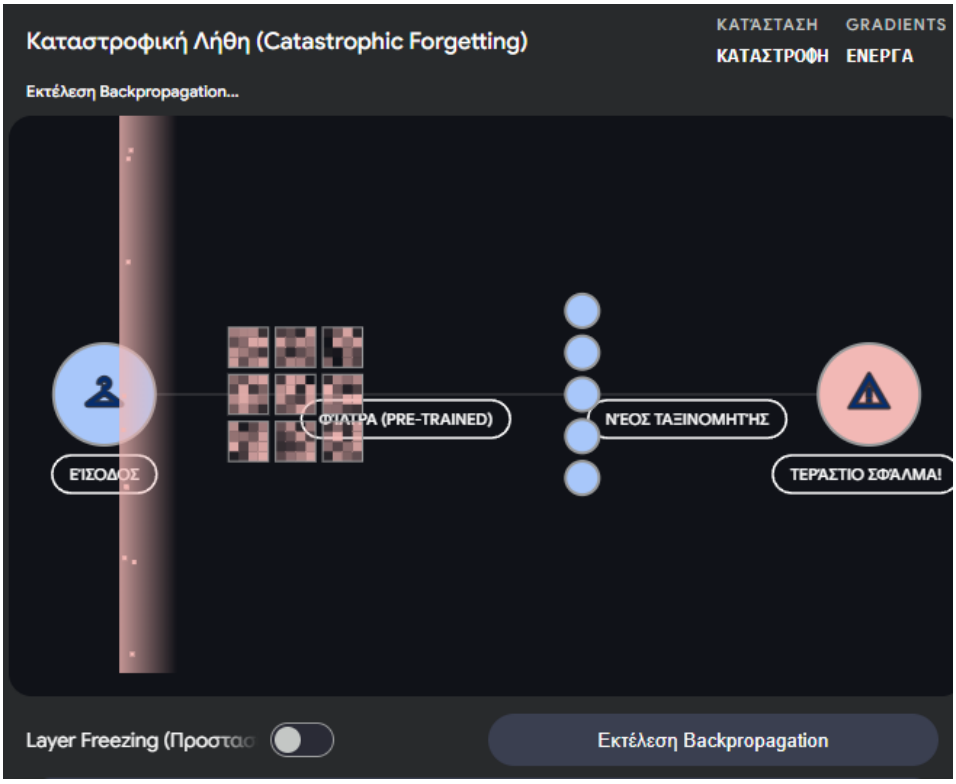
Ακολουθεί μια απλή οπτικοποίηση του Gemini για το πως η καταστροφική λήθη μέσω του backpropagation βλάπτει τα προ-εκπαιδευμένα φίλτρα αναγνώρισης:



"Επιστρέφεται σφάλμα - δεν έχει ξεκινήσει ακόμα το backpropagation"



"Εκτέλεση Backpropagation - ενεργοποιούνται τα gradients "



"Λίγο πριν την λήξη το Backpropagation - τα gradients διέλυσαν τα φίλτρα "

Για την αποφυγή αυτού ακριβώς του κινδύνου, η λογική του Transfer Learning βασίζεται σε δύο σημαντικές φάσεις:

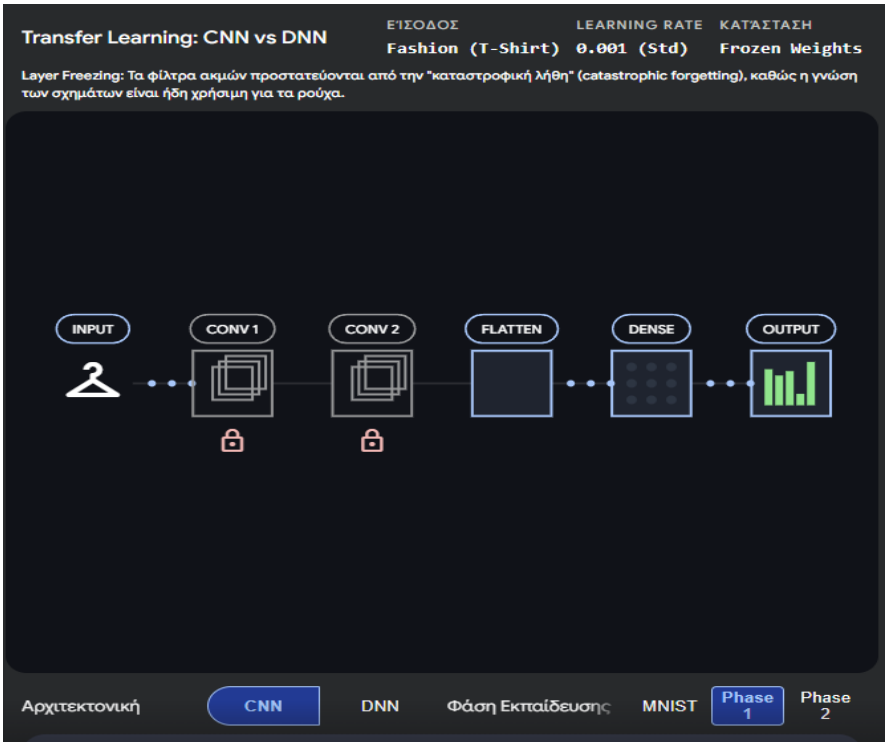
3.1.1 Φάση Α: Δέσμευση Επιπέδων (Layer Freezing):

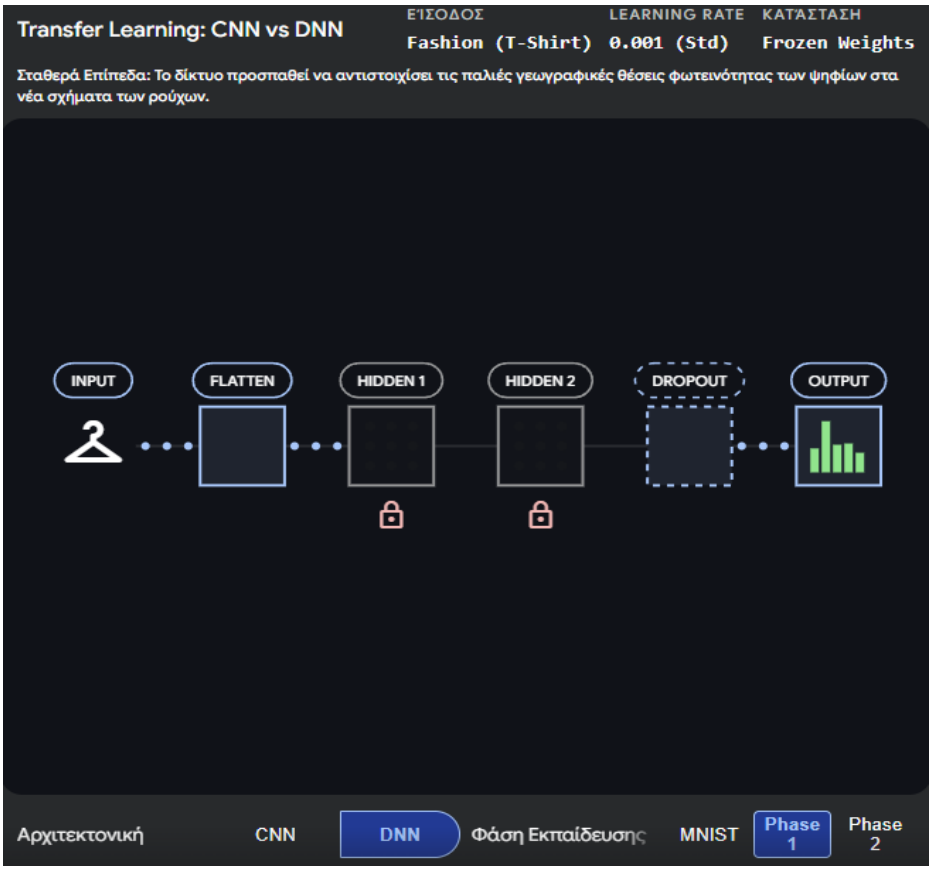
Ως πρώτη γραμμή άμυνας απέναντι στην καταστροφική λήθη, αξιοποιείται η μέθοδος του Layer Freezing. Ο τρόπος σκέψης εκλαϊκευμένα είναι εξαιρετικά απλός:

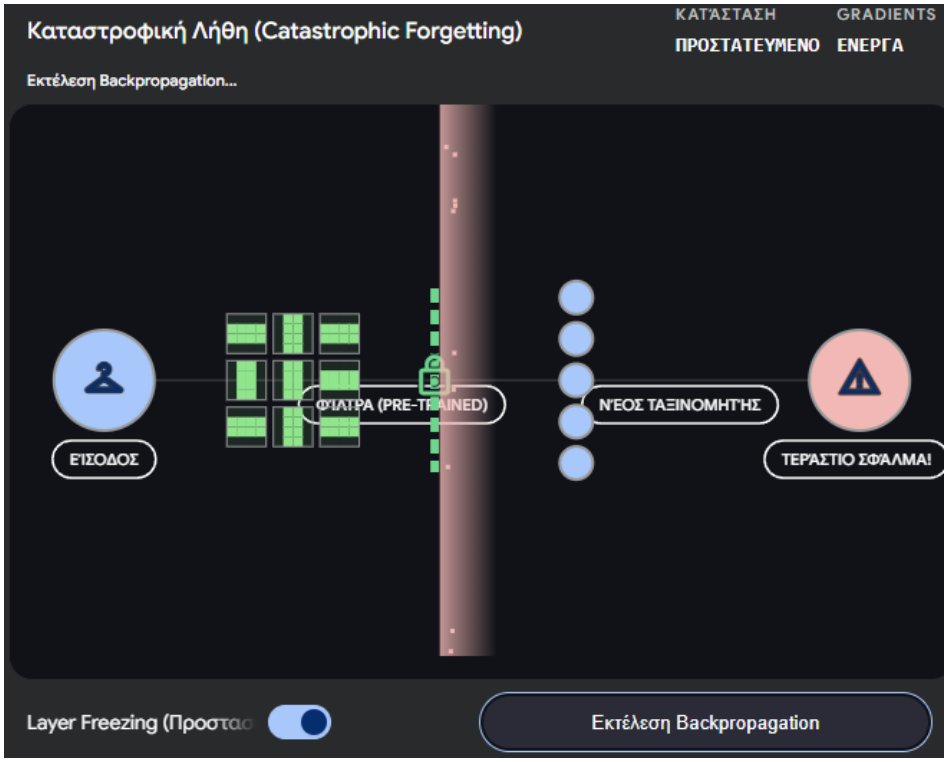
Αποτρέπεται στο μοντέλο η δυνατότητα να ‘‘πειράξει’’ τις προ-εκπαιδευμένες αναγνωριστικές του λειτουργίες. Του επιτρέπεται μόνο η εκπαίδευση πάνω στον προσδιορισμό των κλάσεων και στην κατάλληλη ταξινόμηση. Με άλλα λόγια, δεν του αφήνουμε χώρο να επιρρίψει τις ευθύνες του σφάλματος στον τρόπο που ‘‘βλέπει’’.

Πιο συγκεκριμένα, επιλέξαμε να «κλειδώσουμε» (να αποτρέψουμε δηλαδή την οποιαδήποτε ανανέωση των βαρών κατά το backpropagation) τα αρχικά επίπεδα των δύο προ-εκπαιδευμένων μοντέλων. Στο Συνελικτικό Νευρωνικό Δίκτυο (CNN) δεσμεύτηκαν τα συνελικτικά επίπεδα, προστατεύοντας απόλυτα την ικανότητά τους να εξάγουν καθολικά χαρακτηριστικά (ακμές, γωνίες, καμπύλες). Αντίστοιχα, στο Πλήρως Διασυνδεδεμένο Δίκτυο (DNN), κλειδώθηκαν τα κρυφά πυκνά επίπεδα (Dense layers), διατηρώντας ανέπαφο τον τρόπο με τον οποίο είχαν μάθει να συσχετίζουν χωρικά τα μοτίβα των pixels.

Ακολουθούν οπτικοποιήσεις του Gemini (τα νούμερα του Learning Rate είναι ενδεικτικά):


Transfer Learning: CNN vs DNN
ΕΊΣΟΔΟΣ
Fashion (T-Shirt)
LEARNING RATE
0.001 (Std)
ΚΑΤΆΣΤΑΣΗ
Frozen Weights
Layer Freezing: Τα φίλτρα ακμών προστατεύονται από την "καταστροφική λήθη" (catastrophic forgetting), καθώς η γνώση των σχημάτων είναι ήδη χρήσιμη για τα ρούχα.
INPUT
CONV 1
CONV 2
FLATTEN
DENSE
OUTPUT
Αρχιτεκτονική
CNN
DNN
Φάση Εκπαίδευσης
MNIST
Phase 1
Phase 2


Transfer Learning: CNN vs DNN
ΕΊΣΟΔΟΣ
Fashion (T-Shirt)
LEARNING RATE
0.001 (Std)
ΚΑΤΆΣΤΑΣΗ
Frozen Weights
Σταθερά Επίπεδα: Το δίκτυο προσπαθεί να αντιστοιχίσει τις παλιές γεωγραφικές θέσεις φωτεινότητας των ψηφίων στα νέα σχήματα των ρούχων.
INPUT
FLATTEN
HIDDEN 1
HIDDEN 2
DROPOUT
OUTPUT
Αρχιτεκτονική
CNN
DNN
Φάση Εκπαίδευσης
MNIST
Phase 1
Phase 2



"Το Layer Freezing μπλόκαρε τα gradients "

Έχοντας εξασφαλίσει τη βασική «όραση» των δικτύων, αντικαταστήσαμε το παλιό επίπεδο εξόδου και στις δύο αρχιτεκτονικές με έναν νέο ταξινομητή (ένα νέο επίπεδο Dense 10 νευρώνων) για τις κλάσεις του Fashion-MNIST. Κατά τη διάρκεια αυτής της πρώτης φάσης, η εκπαίδευση (η οποία διήρκησε 40 εποχές) περιορίστηκε αποκλειστικά και μόνο στην προσαρμογή αυτού του νέου ταξινομητή. Πρακτικά, αναγκάσαμε τα μοντέλα να μάθουν τις νέες κατηγορίες ρούχων χρησιμοποιώντας αυστηρά την «παγωμένη» οπτική αντίληψη που είχαν αποκομίσει από τα ψηφία, αποτρέποντας την προς τα πίσω διάδοση των τεράστιων αρχικών σφαλμάτων.

Η θεωρητική προσέγγιση που αναλύθηκε παραπάνω υλοποιήθηκε πλήρως στο προγραμματιστικό περιβάλλον. Στα αποσπάσματα κώδικα που ακολουθούν, αποτυπώνεται η πρακτική εφαρμογή της μεθοδολογίας μέσω της βιβλιοθήκης Keras.

```
# Freeze all layers except the last one
for layer in model.layers[:-1]:
    layer.trainable = False
model.layers[-1].trainable = True
```

Παραπάνω διακρίνεται η προετοιμασία της Φάσης Α, όπου μέσω μιας επαναληπτικής δομής (loop), η ιδιότητα trainable = False εφαρμόζεται σε όλα τα επίπεδα του προ-εκπαιδευμένου δικτύου, εξαιρουμένου του τελευταίου. Η εντολή αυτή αποτελεί την προγραμματιστική υλοποίηση της "προστασίας" έναντι της καταστροφικής λήθης.

```
# Model 3: CNN Transfer
model3 = get_transfer_model('/content/cnn_model_final.h5')
model3.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=40, batch_size=125, verbose=0)
```

```
# Model 4: DNN Transfer
model4 = get_transfer_model('/content/dnn_model_final.h5')
model4.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=40, batch_size=125, verbose=0)
```

Η διαδικασία ολοκληρώνεται με τη ροή της εκπαίδευσης. Μέσω της συνάρτησης *get_transfer_model*, το δίκτυο φορτώνεται με τον νέο ταξινομητή και η εκπαίδευση ενεργοποιείται για 40 εποχές (batch size 125). Σε αυτούς τους κύκλους, ανανεώνονται αυστηρά μόνο τα βάρη του νέου, ξεκλείδωτου επιπέδου. Ταυτόχρονα, η χρήση της παραμέτρου *validation_data* διασφαλίζει τον συνεχή έλεγχο της απόδοσης, αφήνοντας την προ-εκπαιδευμένη εσωτερική δομή εντελώς ανέπαφη.

3.1.2 Φάση Β: Μικρορύθμιση (Fine Tuning):

Με το πέρας της φάσης Α, ο νέος ταξινομητής έχει εξοικειωθεί με το νέο "λεξιλόγιο" (τις 10 κλάσεις των ενδυμασιών) , χωρίς να έχει αλλοιώσει τις αναγνωριστικές του δεξιότητες. Συνεπώς, ως ένα σημείο το μοντέλο είναι ικανό να αναγνωρίσει τις ακμές και τις γωνίες μίας μπότας , και τελικά να ταξινομήσει την εικόνα κατάλληλα με πολύ μικρότερο σφάλμα - αρκετά μικρότερο ώστε τα gradients που θα στείλει το backpropagation πιθανοτικά να μην προκαλέσουν ριζικές αλλαγές.

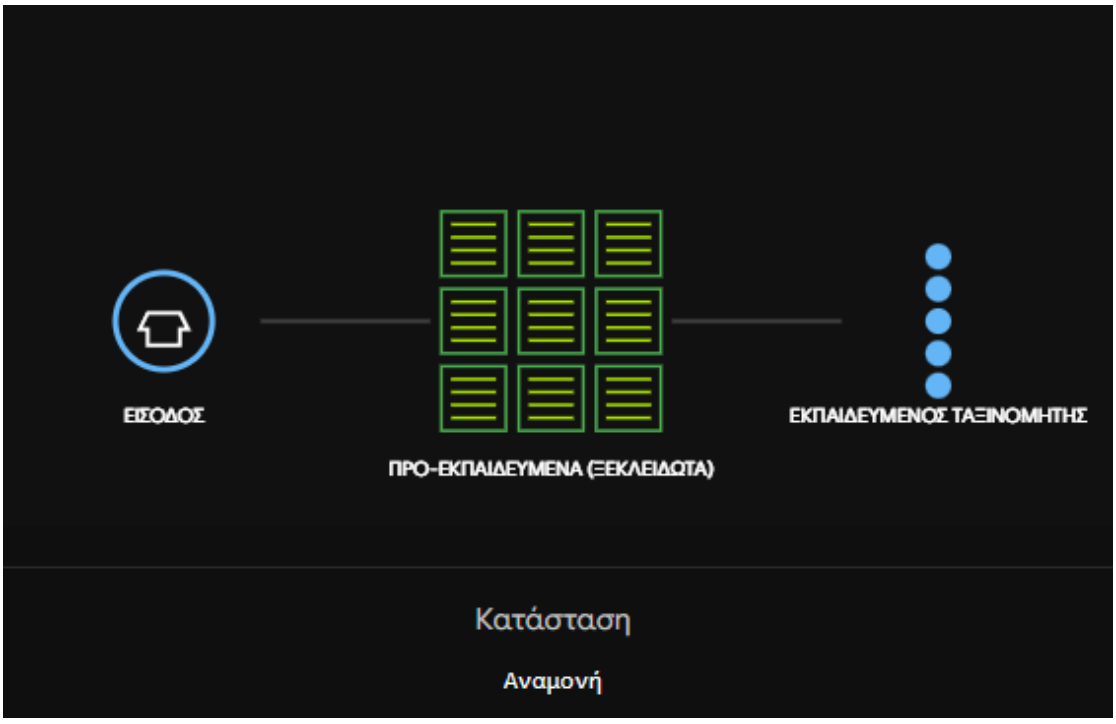
Παρόλα αυτά, οι ακμές και οι γωνίες ενός ρούχου διαφέρουν ως ένα βαθμό με τα αντίστοιχα του ψηφίου 7. Επομένως, αφού εξασφαλίστηκε ότι δεν χάθηκε η

ήδη υπάρχουσα "όραση" του μοντέλου, είμαστε πλέον σε θέση να την τελειοποιήσουμε.

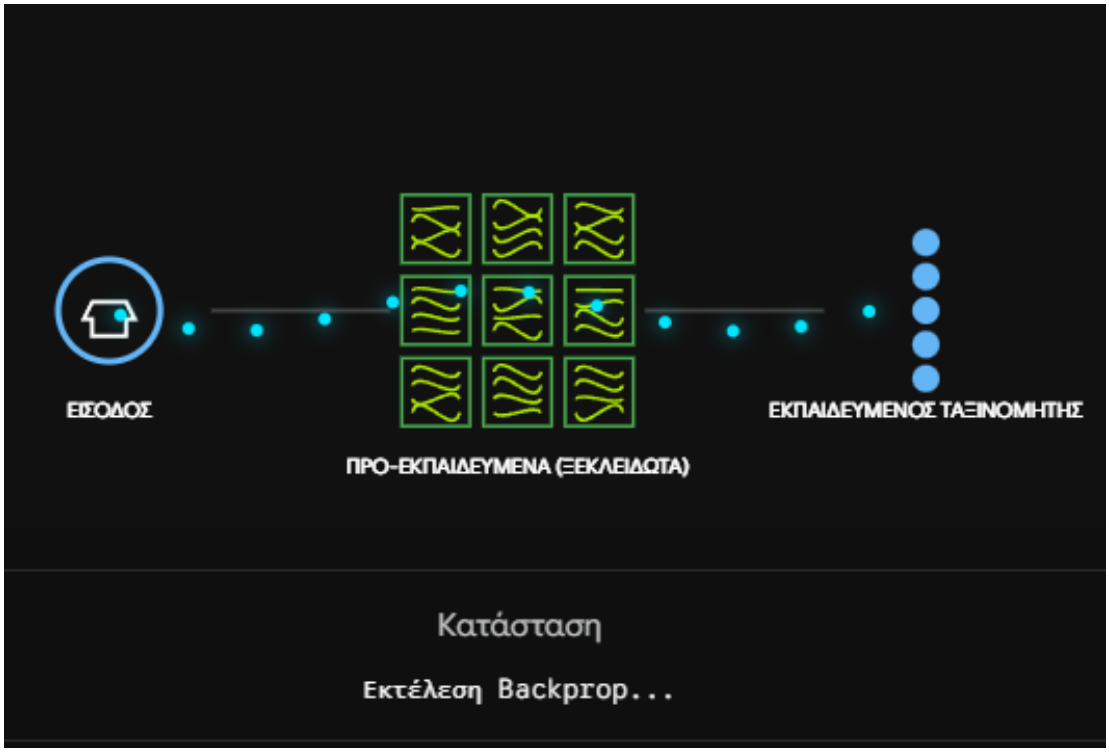
Αυτό ακριβώς εξασφαλίζει η φάση Β του Fine Tuning, οι αναγνωριστικές τάσεις του δικτύου ρυθμίζονται σταδιακά, ώστε να εναρμονίζονται με τις οπτικές ιδιαιτερότητες των νέων δεδομένων.

Η διαδικασία είναι απλή: Αρχικά τα πρώτα επίπεδα ξεκλειδώνονται και η εκπαίδευση συνεχίζει κανονικά. Ωστόσο, παρόλο που ο κίνδυνος κατάρρευσης της υπάρχουσας γνώσης έχει περιοριστεί, δεν έχει εξαφανιστεί. Για αυτόν τον λόγο λαμβάνονται μέτρα ασφαλείας και η εκπαίδευση γίνεται με πολύ μικρά "βήματα" (μικρό Learning Rate). Με αυτόν τον τρόπο ακόμα και αν τα Gradients συνιστούν έντονη τροποποίηση των αρχικών βαρών, η τελική μετατροπή θα είναι μικροσκοπική.

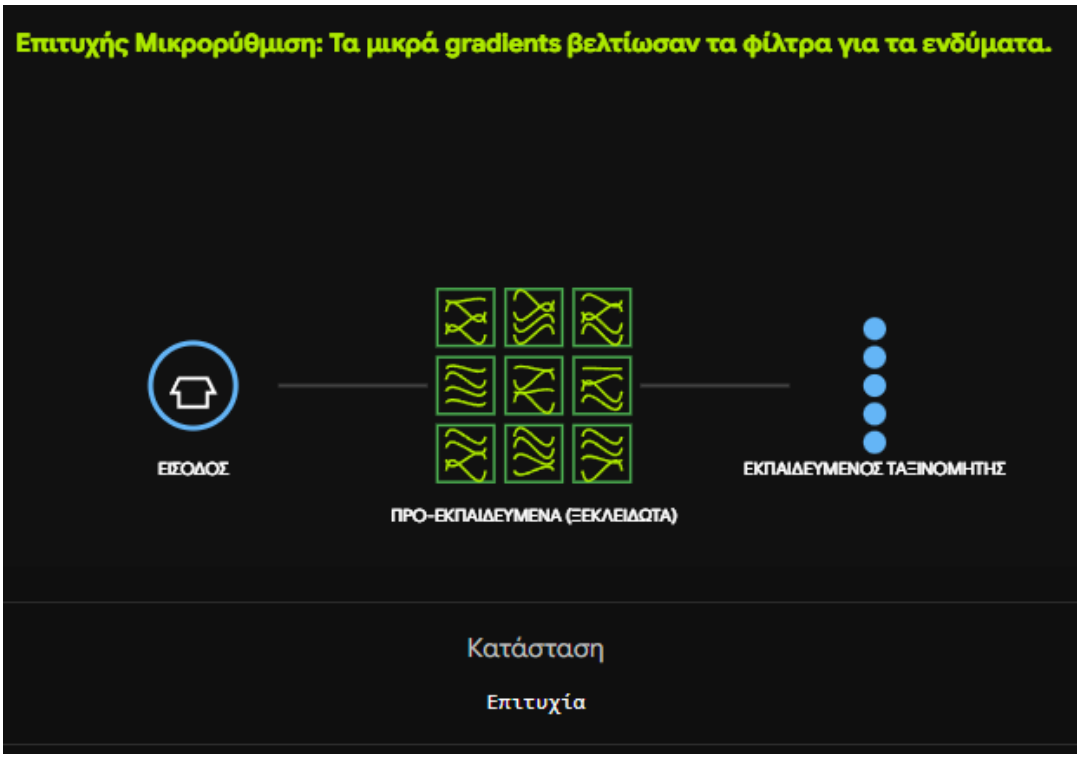
Παρακάτω ακολουθούν απλοϊκές οπτικοποιήσεις του Gemini, όπου το backpropagation γίνεται με μικρό Learning Rate:



"Τα επίπεδα ξεκλειδώνονται - δεν έχει ξεκινήσει ακόμα το backpropagation"



"Εκτέλεση - τα βάρη των φίλτρων προσαρμόζονται ήπια"



"Ολοκλήρωση μικρορύθμισης"

Στην πρακτική υλοποίηση, τον ρόλο του "μηχανισμού ασφαλείας" για την ομαλή προσαρμογή των βαρών ανέλαβε ο αλγόριθμος βελτιστοποίησης Adam

(Adaptive Moment Estimation). Το μεγάλο πλεονέκτημα του Adam στο Fine-Tuning είναι ότι προσαρμόζει δυναμικά τον ρυθμό μάθησης (adaptive learning rate) για κάθε παράμετρο ξεχωριστά, λαμβάνοντας υπόψη την ιστορικότητα των Gradients. Αυτό εξασφαλίζει ότι οι ανανεώσεις στα ήδη εκπαιδευμένα βάρη των αρχικών επιπέδων θα γίνουν εξαιρετικά ήπια και στοχευμένα, αποτρέποντας την αλλοίωση της προϋπάρχουσας γεωμετρικής τους αντίληψης.

Η διαδικασία αυτή αποτυπώνεται στο επόμενο απόσπασμα κώδικα. Αρχικά, το σύνολο του δικτύου "ξεκλειδώνεται" μέσω της εντολής *trainable = True*, δίνοντας ξανά πρόσβαση στο Backpropagation σε όλα τα επίπεδα. Αμέσως μετά, το μοντέλο μεταγλωττίζεται εκ νέου (compile) προκειμένου να καταχωρηθεί η νέα κατάσταση των επιπέδων και να οριστεί ο αλγόριθμος Adam. Τέλος, η εκπαίδευση της Φάσης Β εκκινεί *(.fit())* και συνεχίζεται για 20 επιπλέον εποχές. Σε αυτούς τους κύκλους, το δίκτυο εναρμονίζει πλήρως τα φίλτρα του με τα νέα δεδομένα, ολοκληρώνοντας με επιτυχία τη διαδικασία της μικρορύθμισης. Οι πρώτες δύο γραμμές στα δύο μοντέλα αφορούν το Layer Freezing.

```
# Model 3: CNN Transfer
model3 = get_transfer_model('/content/cnn_model_final.h5')
model3.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=40, batch_size=125, verbose=0)
model3.trainable = True
model3.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
model3.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=20, batch_size=125, verbose=0)
evaluate_and_append(model3, 'CNN _transfer', fold_idx)

# Model 4: DNN Transfer
model4 = get_transfer_model('/content/dnn_model_final.h5')
model4.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=40, batch_size=125, verbose=0)
model4.trainable = True
model4.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
model4.fit(X_fold_train, Y_fold_train, validation_data=(X_fold_val, Y_fold_val), epochs=20, batch_size=125, verbose=0)
evaluate_and_append(model4, 'DNN _transfer', fold_idx)
```

3.2 Παρουσίαση Αποτελεσμάτων

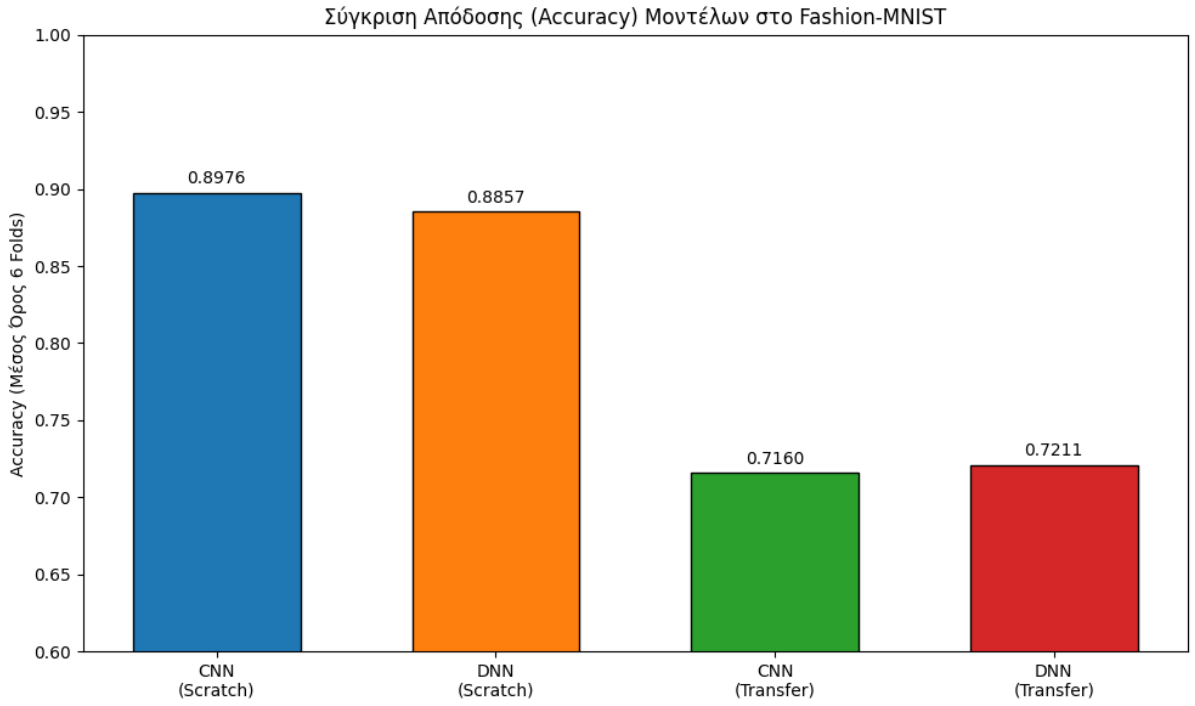
Προκειμένου να αποτιμηθεί με αντικειμενικότητα η πραγματική συνεισφορά της στρατηγικής της Μεταφοράς Μάθησης, κρίθηκε απαραίτητη η δημιουργία ενός

μέτρου σύγκρισης. Για τον σκοπό αυτό, υλοποιήθηκαν και εκπαιδεύτηκαν από το μηδέν (from scratch) δύο νέα μοντέλα, ένα Συνελικτικό (CNN) και ένα Πλήρως Διασυνδεδεμένο (DNN), προσαρμοσμένα αυτή τη φορά εξαρχής στα δεδομένα του Fashion-MNIST.

Η προσέγγιση αυτή επιτρέπει την άμεση αντιπαραβολή ανάμεσα στα μοντέλα που "έχτισαν" τη γνώση τους αποκλειστικά πάνω στο νέο σύνολο δεδομένων, και σε εκείνα που αξιοποίησαν την προ-εκπαιδευμένη "όραση" από τα ψηφία του MNIST (μέσω των φάσεων Layer Freezing και Fine-Tuning).

Για την συγκριτική αξιολόγηση παρατίθενται τα συγκριτικά αποτελέσματα των πειραμάτων πάνω στο σύνολο Fashion-MNIST. Όπως και στην δεύτερη ενότητα, οι τιμές που παρουσιάζονται αποτελούν τον μέσο όρο των 6 ανεξάρτητων εκτελέσεων (folds) για τα τέσσερα συνολικά μοντέλα: τα δύο που εκπαιδεύτηκαν από το μηδέν (From Scratch) και τα δύο που αξιοποίησαν προ-εκπαιδευμένα βάρη (Transfer Learning).

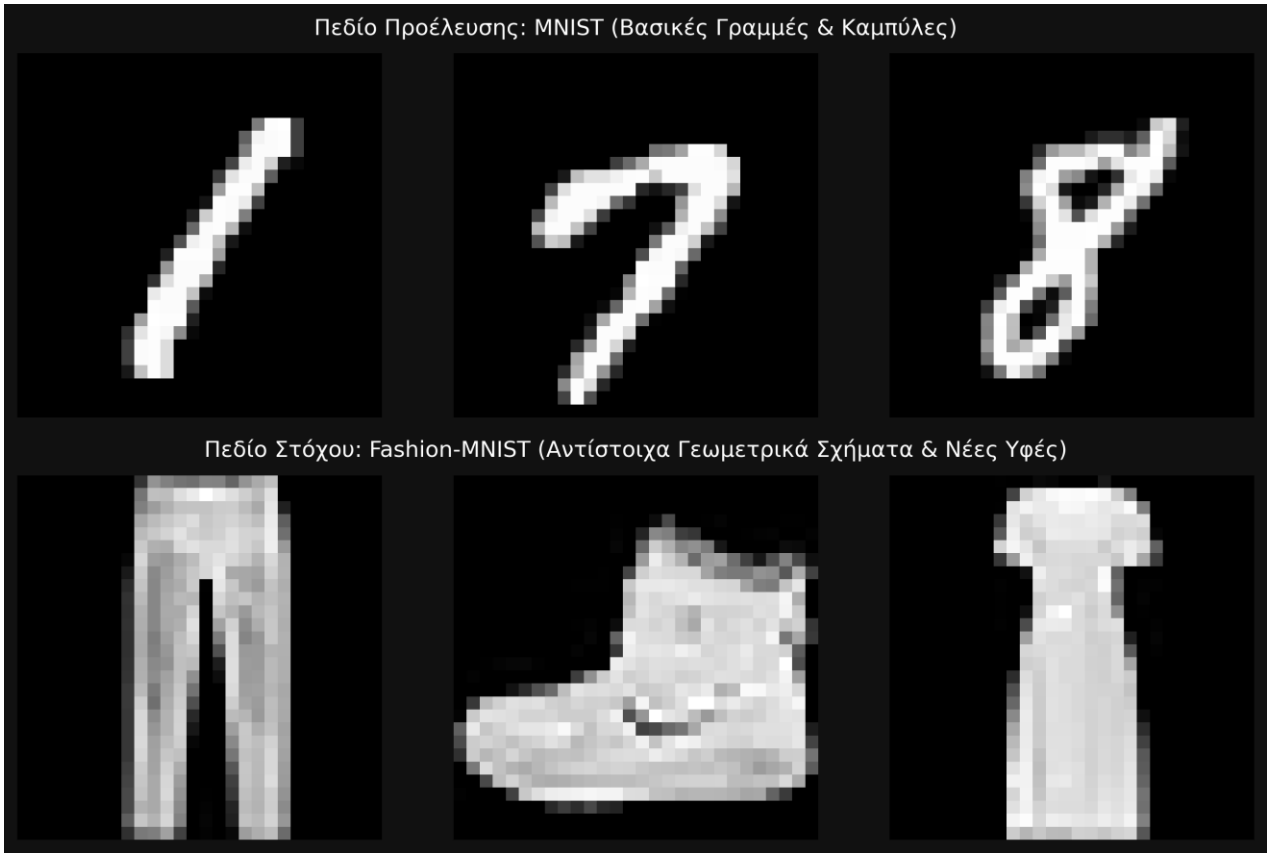
3.2.1 From Scratch VS Transfer Learning



Τα αποτελέσματα αναδεικνύουν μια ξεκάθαρη τάση: τα μοντέλα που εκπαιδεύτηκαν εξ ολοκλήρου από το μηδέν (From Scratch) υπερτερούν συντριπτικά. Συγκεκριμένα, το CNN (Scratch) σημείωσε την υψηλότερη απόδοση φτάνοντας το **89.76%**, ακολουθούμενο στενά από το DNN (Scratch) με **88.57%**. Αντιθέτως, η εφαρμογή της στρατηγικής του Transfer Learning οδήγησε σε σημαντική πτώση της απόδοσης, με το DNN (Transfer) να περιορίζεται στο **72.11%** και το CNN (Transfer) στο **71.60%**.

Εκ πρώτης όψεως, οι αρχιτεκτονικές “From Scratch” επιδεικνύουν πράγματι σαφή υπεροχή στο συγκεκριμένο πρόβλημα ταξινόμησης. Ωστόσο, αναλύοντας τον θεωρητικό μηχανισμό λειτουργίας της Μεταφοράς Μάθησης (Transfer Learning), το αποτέλεσμα αυτό είναι απόλυτα αναμενόμενο.

3.3 Ανάλυση της "Μετατόπισης Πεδίου" (Domain Shift)



“Παραδείγματα γεωμετρικής αντιστοιχίας μεταξύ MNIST και Fashion-MNIST. Η αδυναμία των προ-εκπαιδευμένων φίλτρων να διαχειριστούν τις νέες, πολύπλοκες υφές αποτελεί την κύρια αιτία της υστέρησης του Transfer Learning.”

Παραπάνω απεικονίζεται μια προσπάθεια γεωμετρικής αντιστοιχίας μεταξύ των δύο συνόλων δεδομένων. Όπως προαναφέρθηκε και όπως διακρίνεται στην οπτικοποίηση, παρόλο που οι γεωμετρικές ιδιαιτερότητες ενός ψηφίου και μιας ενδυμασίας μπορεί να παρουσιάζουν βασικές δομικές ομοιότητες, στην πράξη η μορφολογική τους απόκλιση είναι σημαντική.

Κατά τη διάρκεια της Μεταφοράς Μάθησης, τα δίκτυα εκπαιδεύτηκαν στα νέα δεδομένα. Ωστόσο, μέσω του Layer Freezing και του χαμηλού Learning Rate στη φάση του Fine Tuning, διαφυλάχθηκε σε μεγάλο βαθμό η αρχική τους εξειδίκευση στο σύνολο του MNIST.

Επομένως, τα προ-εκπαιδευμένα δίκτυα κλήθηκαν να αντιμετωπίσουν το φαινόμενο της «Μετατόπισης Πεδίου» (Domain Shift), το οποίο ουσιαστικά υποδηλώνει πως: ενώ το κύριο μέρος της αναγνωριστικής τους ικανότητας αναπτύχθηκε σε ένα συγκεκριμένο πεδίο (MNIST), κλήθηκαν τελικά να αξιολογηθούν σε ένα νέο, με διαφορετικά οπτικά χαρακτηριστικά (Fashion-MNIST).

Με άλλα λόγια, το 71-72% που πέτυχαν τα προ-εκπαιδευμένα μοντέλα οφείλεται ακριβώς σε αυτή τη στοιχειώδη γεωμετρική συγγένεια μεταξύ των δεδομένων, αλλά και στην αποτελεσματικότητα της μικρορύθμισης κατά το Fine Tuning. Σε καμία περίπτωση, όμως, δεν θα μπορούσαν να προσεγγίσουν το 88-89% που σημείωσαν τα μοντέλα «From Scratch», τα οποία σχεδιάστηκαν και εκπαιδευτήκαν εξαρχής με αποκλειστικό σκοπό την ταξινόμηση των πολύπλοκων υφών του Fashion-MNIST.

Έχοντας λάβει υπόψιν όλα τα παραπάνω, θα μπορούσε να εξαχθεί το συμπέρασμα πως η τεχνική του Transfer Learning δεν έχει ουσιαστική χρησιμότητα σε σχέση με την εκπαίδευση από το μηδέν. Ωστόσο, μια τέτοια γενίκευση δεν ευσταθεί. Στο εξεταζόμενο πρόβλημα, ο πρωταρχικός λόγος που τα μοντέλα "From Scratch" υπερτερούν, εντοπίζεται στον τεράστιο όγκο των διαθέσιμων δεδομένων εκπαίδευσης του Fashion-MNIST - συγκεκριμένα 70.000 εικόνες.

Σε ένα σενάριο όπου το μέγεθος του συνόλου δεδομένων θα ήταν σημαντικά μικρότερο (όπως για παράδειγμα στην ανίχνευση μιας καινούργιας ασθένειας), η προσέγγιση της Μεταφοράς Μάθησης - υπό την προϋπόθεση ότι χρησιμοποιείται ένα κατάλληλο, προ-εκπαιδευμένο δίκτυο - αναδεικνύεται κατά κανόνα ως η βέλτιστη λύση, χάρη στην εξαιρετική δομική σταθερότητα που παρέχει.

3.4 Σταθερότητα των Προ-εκπαιδευμένων Μοντέλων

	Technique name	Set	Fold number	Accuracy	Precision	Recall	F1 score
0	CNN from_scratch	Train	1	0.96364	0.963936	0.96364	0.963198
1	CNN from_scratch	Test	1	0.89870	0.898112	0.89870	0.897720
2	DNN from_scratch	Train	1	0.97670	0.976691	0.97670	0.976685
3	DNN from_scratch	Test	1	0.89190	0.892219	0.89190	0.891894
4	CNN _transfer	Train	1	0.72524	0.717230	0.72524	0.716714
5	CNN _transfer	Test	1	0.71710	0.709880	0.71710	0.708805
6	DNN _transfer	Train	1	0.72732	0.718798	0.72732	0.719901
7	DNN _transfer	Test	1	0.72250	0.713697	0.72250	0.715532

"Σύγκριση απόδοσης στο FOLLI 1, όπου επιβεβαιώνεται το χάσμα υπερεκπαίδευσης στα μοντέλα «From Scratch» έναντι της σταθερότητας του «Transfer Learning». *Η συγκεκριμένη τάση επιβεβαιώθηκε με απόλυτη συνέπεια σε όλα τα Folds της διασταυρούμενης επικύρωσης.*"

Με τον όρο «δομική σταθερότητα» στο πλαίσιο της Βαθιάς Μάθησης αναφερόμαστε στην ικανότητα ενός νευρωνικού δικτύου να διατηρεί αναλλοίωτη και συνεπή την αναγνωριστική του συμπεριφορά κατά τη μετάβαση από το περιβάλλον εκπαίδευσης σε συνθήκες πραγματικής αξιολόγησης.

Αναλύοντας το παραπάνω απόσπασμα του DataFrame, εξάγεται ένα κρίσιμο συμπέρασμα σχετικά με τη συμπεριφορά των δικτύων: Τα μοντέλα «From Scratch» επιτυγχάνουν υψηλότατη ακρίβεια (Accuracy) της τάξης του **96-97%** στο σύνολο εκπαίδευσης (Train Set), η οποία ωστόσο υποχωρεί στο **89%** κατά την αξιολόγηση στο σύνολο δοκιμής (Test Set) — καταγράφοντας πτώση μεγαλύτερη του **6.5%**. Στον αντίποδα, τα μοντέλα Μεταφοράς Μάθησης (Transfer Learning) σημειώνουν ακρίβεια **~72%** στο σύνολο εκπαίδευσης, την οποία όμως διατηρούν σχεδόν αναλλοίωτη και κατά τη φάση της αξιολόγησης, με τη μεταξύ τους απόκλιση να περιορίζεται αυστηρά σε ποσοστό μικρότερο του **1%**.

Η παραπάνω παρατήρηση ερμηνεύεται ως εξής: Τα δίκτυα Μεταφοράς Μάθησης (Transfer Learning) μπορεί να σημείωσαν χαμηλότερη συνολική ακρίβεια, αλλά στην ουσία είναι πιο αξιόπιστα, γιατί όσα γνωρίζουν τα γνωρίζουν πραγματικά - έχουν εξαιρετική ικανότητα γενίκευσης. Το ποσοστό που επιτεύχθηκε στο σύνολο εκπαίδευσης (Train Set), διατηρήθηκε με απόλυτη συνέπεια και στο σύνολο δοκιμής (Test Set) χωρίς να δημιουργεί ψευδαισθήσεις.

Αντιθέτως, η πτώση της απόδοσης που παρατηρήθηκε στα μοντέλα "From Scratch" κατά τη μετάβαση σε άγνωστα δεδομένα, υποδηλώνει ότι ένα μέρος της υψηλής ακρίβειάς τους οφείλεται σε φαινόμενα υπερεκπαίδευσης (overfitting) και όχι σε ουσιαστική εκμάθηση των χαρακτηριστικών. Το δίκτυο προσαρμόστηκε και «αποστήθισε» συγκεκριμένα μοτίβα και στατιστικό θόρυβο των δεδομένων εκπαίδευσης, τα οποία, όταν απουσίαζαν από τη φάση της αξιολόγησης, οδήγησαν στη μαθηματικά αναμενόμενη μείωση της ακρίβειας.

Η ριζική αυτή διαφορά στη συμπεριφορά των δύο προσεγγίσεων ερμηνεύεται μέσα από την αρχιτεκτονική ελευθερία των παραμέτρων και την ύπαρξη προϋπάρχουσας γνώσης.

Συγκεκριμένα, τα μοντέλα «From Scratch» ξεκινούν την εκπαίδευσή τους με εκατομμύρια τυχαία αρχικοποιημένα βάρη. Έχοντας τον πλήρη έλεγχο και την απόλυτη ελευθερία να αναπροσαρμόσουν το κάθε φίλτρο τους από το μηδέν, διαθέτουν τεράστια «χωρητικότητα» - δηλαδή μεγάλο πλήθος ελεύθερων παραμέτρων. Στην προσπάθειά τους να ελαχιστοποιήσουν το σφάλμα, εκμεταλλεύονται αυτή την απεριόριστη παραμετρική ελευθερία για να προσαρμοστούν ακόμα και στις πιο ασήμαντες λεπτομέρειες των διαθέσιμων δεδομένων, πέφτοντας αναπόφευκτα στην παγίδα της υπερεκπαίδευσης.

Σε πλήρη αντίθεση, τα μοντέλα Transfer Learning προστατεύονται από αυτό το φαινόμενο χάρη στην τεχνική του Layer Freezing. Διατηρώντας «παγωμένα» τα συνελικτικά επίπεδα, το δίκτυο στερείται την ελευθερία να αλλοιώσει αυθαίρετα τα βάρη του. Εφόσον ο μηχανισμός εξαγωγής χαρακτηριστικών (feature extractor) είναι ήδη «κλειδωμένος» στη σταθερή αναγνώριση θεμελιωδών γεωμετρικών δομών, το μοντέλο δρα ως ένας ισχυρός ρυθμιστής (regularizer). Αναγκάζεται, έτσι, να αναζητήσει γενικεύσιμους κανόνες, καθιστώντας πρακτικά αδύνατη την αποστήθιση του στατιστικού θορύβου του νέου συνόλου δεδομένων.

Εδώ ακριβώς έγκειται το ισχυρότερο πλεονέκτημα της Μεταφοράς Μάθησης. Σε σενάρια όπου τα διαθέσιμα δεδομένα κρίνονται ανεπαρκή για την εκπαίδευση ενός δικτύου — είτε λόγω περιορισμένου όγκου δείγματος, είτε λόγω έντονου στατιστικού θορύβου — αξιοποιείται η εδραιωμένη γνώση ενός προ-εκπαιδευμένου μοντέλου, η οποία στη συνέχεια προσαρμόζεται (fine-tuned) στο νέο, στοχευμένο σύνολο. Με αυτή τη στρατηγική, αποτρέπεται ριζικά το φαινόμενο της υπερεκπαίδευσης και διασφαλίζεται η βέλτιστη δυνατή ικανότητα γενίκευσης

Πολλές φορές, ακόμη και σε περιπτώσεις με απόλυτα επαρκή δεδομένα, η Μεταφορά Μάθησης αποτελεί και πάλι πρώτη επιλογή για αρκετούς ερευνητές. Συμφέρει και ως προς το υπολογιστικό κόστος σε σχέση με την εκπαίδευση από

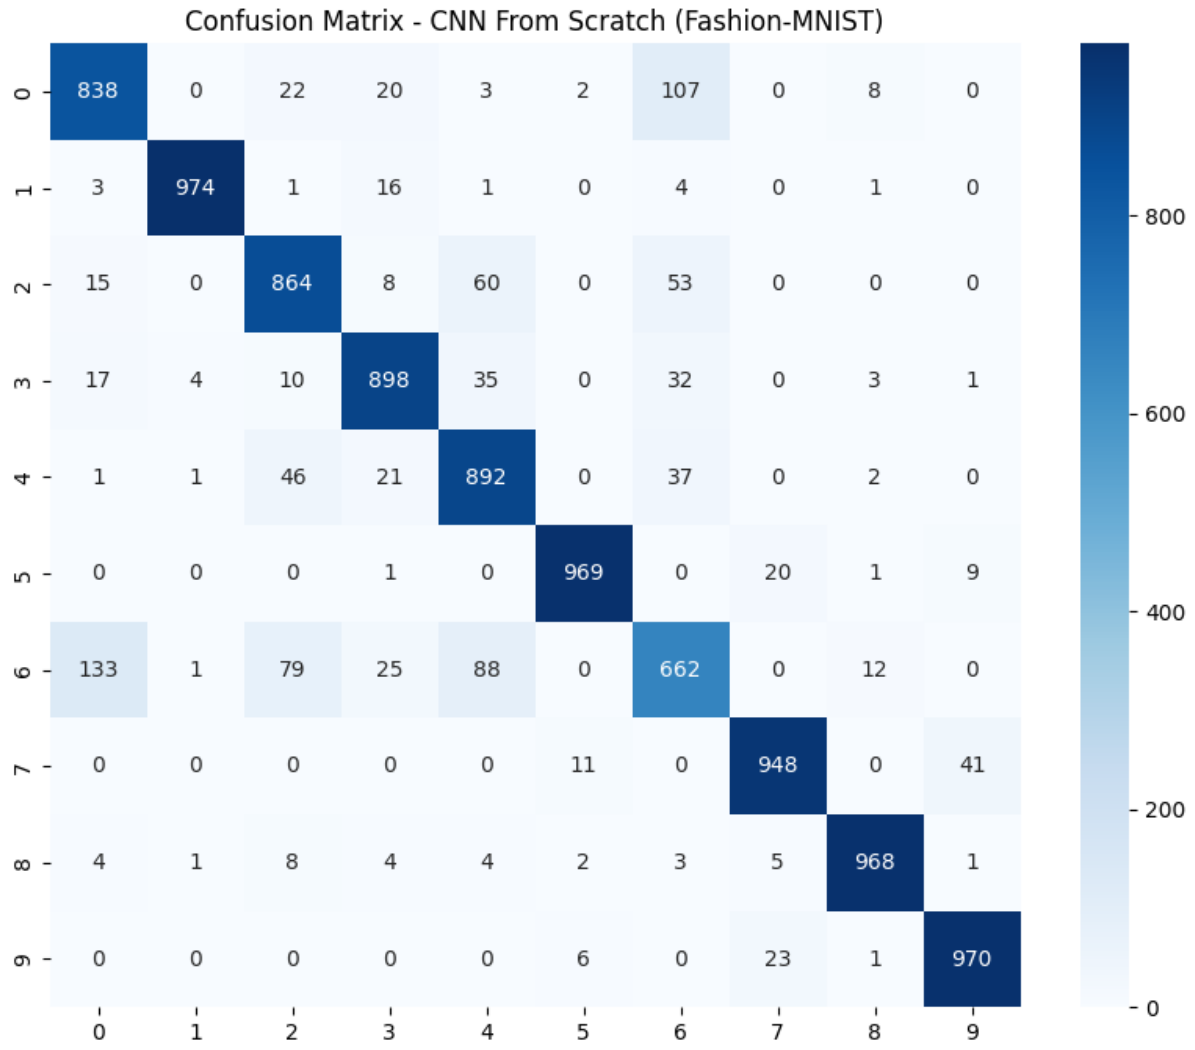
το μηδέν και παρέχει μια δοκιμασμένη αρχικοποίηση βαρών, η οποία εξασφαλίζει ταχύτερη σύγκλιση και μειώνει τον κίνδυνο του εγκλωβισμού του αλγορίθμου σε υποδεέστερα τοπικά ελάχιστα.

4. ΕΝ ΤΩ ΒΑΘΕΙ ΑΝΑΛΥΣΗ

Με την επιτυχή ολοκλήρωση των βασικών ερευνητικών ζητουμένων της μελέτης, η παρούσα ενότητα εστιάζει στην εν τω βάθει αξιολόγηση του Συνελικτικού Νευρωνικού Δικτύου (CNN) που εκπαιδεύτηκε από το μηδέν (From Scratch). Η επιλογή του συγκεκριμένου μοντέλου για περαιτέρω διερεύνηση υπαγορεύεται από το γεγονός ότι ανταποκρίθηκε βέλτιστα στην οπτική πολυπλοκότητα του συνόλου δεδομένων Fashion-MNIST, καταγράφοντας την υψηλότερη προβλεπτική ικανότητα.

Συγκεκριμένα, η ανάλυση θα προχωρήσει πέρα από τις συγκεντρωτικές μετρικές απόδοσης, μελετώντας διεξοδικά τη συμπεριφορά του δικτύου κατά τη φάση της αξιολόγησης (Test Set). Μέσω της οπτικοποίησης του Πίνακα Σύγχυσης (Confusion Matrix), θα χαρτογραφηθούν οι ακριβείς δυσλειτουργίες και οι ταξινομικές συγχύσεις μεταξύ παρεμφερών κλάσεων, επιτρέποντας μια στοχευμένη ανάλυση σφαλμάτων για την ερμηνεία των αδυναμιών του αλγορίθμου και, τελικά, τη διατύπωση προτάσεων για την περαιτέρω ενίσχυση της προβλεπτικής του ικανότητας.

4.1 Confusion Matrix Heatmap



"Πίνακας Σύγχυσης - CNN from scratch"

Για την ορθή ερμηνεία του διαγράμματος, ορίζεται η εξής σύμβαση ανάγνωσης: οι οριζόντιες γραμμές του πίνακα αναπαριστούν την **Πραγματική Κλάση** (True Label) στην οποία ανήκει ένα αντικείμενο, ενώ οι κάθετες στήλες υποδεικνύουν την **Προβλεπόμενη Κλάση** (Predicted Label) που απέδωσε το νευρωνικό δίκτυο.

Βάσει αυτής της δομής, προκύπτουν δύο θεμελιώδεις περιοχές ενδιαφέροντος:

1. **Η Κύρια Διαγώνιος:** Απαρτίζεται από τα κελιά όπου η πραγματική κλάση ταυτίζεται με την προβλεπόμενη (True Positives). Σε ένα ιδεατό, αλάνθαστο μοντέλο, το σύνολο των προβλέψεων θα συγκεντρωνόταν αποκλειστικά σε αυτή τη διαγώνιο. Επομένως, επιδιώκεται τα κελιά αυτά να παρουσιάζουν τις μέγιστες δυνατές τιμές (οπτικοποιημένα με την εντονότερη χρωματική απόχρωση), επιβεβαιώνοντας την υψηλή αυτοπεποίθηση και ορθότητα του αλγορίθμου.

2. **Τα Εκτός Διαγωνίου Κελιά:** Οποιαδήποτε τιμή καταγράφεται εκτός της κύριας διαγωνίου συνιστά ταξινομικό σφάλμα (misclassification). Τα κελιά

αυτά καταδεικνύουν ακριβώς πού και πόσο συχνά το μοντέλο «μπερδεύει» δύο συγκεκριμένες κατηγορίες μεταξύ τους. Για την εξασφάλιση της αξιοπιστίας του συστήματος, τα νούμερα σε αυτές τις περιοχές πρέπει να τείνουν στο μηδέν.

Αναλύοντας τα ευρήματα του Πίνακα Σύγχυσης στο σύνολο δοκιμής, αναδεικνύονται δύο ξεκάθαρες τάσεις ως προς την αναγνωριστική του ικανότητα.

Αφενός, το δίκτυο επιδεικνύει εξαιρετική ακρίβεια και καταγράφει εντυπωσιακά υψηλές τιμές στην κύρια διαγώνιο για κατηγορίες αντικειμένων που φέρουν απολύτως διακριτά και μοναδικά μορφολογικά χαρακτηριστικά. Πιο συγκεκριμένα, η κλάση 1 (Trouser/Παντελόνι) αναγνωρίστηκε ορθά σε 974 περιπτώσεις, ενώ παρόμοια επίπεδα επιτυχίας σημειώθηκαν στα υποδήματα (γραμμές 5, 7 και 9 με 969, 948 και 970 ορθές προβλέψεις αντίστοιχα) και στις τσάντες (κλάση 8 με 968 ορθές προβλέψεις).

Αφετέρου, εντοπίζεται μια εκτεταμένη ζώνη ταξινομικής αστοχίας που αφορά αποκλειστικά τα ενδύματα του άνω κορμού. Τα υψηλότερα νούμερα εκτός διαγωνίου —και συνεπώς η πηγή της απώλειας του 10% από τη συνολική ακρίβεια— επικεντρώνονται γύρω από την κλάση 6 (Shirt/Πουκάμισο). Το δίκτυο κατόρθωσε να αναγνωρίσει ορθά μόλις 662 πουκάμισα. Στις υπόλοιπες περιπτώσεις σημειώθηκε έντονη σύγχυση, καθώς το μοντέλο ταξινόμησε λανθασμένα τα πουκάμισα ως T-shirts (133 φορές), ως Coats (88 φορές) και ως Pullovers (79 φορές).

Η αστοχία αυτή είναι αμφίδρομη, καθώς και τα T-shirts (κλάση 0) ταξινομήθηκαν λανθασμένα ως Πουκάμισα σε 107 περιπτώσεις. Αντίστοιχες συγχύσεις παρατηρούνται και μεταξύ των κλάσεων 2 (Pullover) και 4 (Coat).

Για να αξιοποιήσουμε ουσιαστικά τις παραπάνω πληροφορίες και να αναλάβουμε πιο στοχευμένες δράσεις, είναι κρίσιμο να αναλογιστούμε για τις πιθανές αιτίες που οδηγούν σε αυτές τις δυσλειτουργίες.

4.2 Ανάλυση Σφαλμάτων

Όπως διαπιστώθηκε από την ανάλυση του Πίνακα Σύγχυσης, το μοντέλο παρουσιάζει συστηματική δυσκολία στην ταξινόμηση των ενδυμάτων του άνω κορμού. Το φαινόμενο αυτό κρίνεται θεωρητικά αναμενόμενο, εάν ληφθούν υπόψη οι τοπολογικές και μορφολογικές ιδιαιτερότητες τόσο των ίδιων των ενδυμάτων όσο και του συνόλου δεδομένων Fashion-MNIST.

Εξετάζοντας, για παράδειγμα, την κατηγορία του παντελονιού (Κλάση 1), παρατηρείται ένα απολύτως διακριτό και ξεκάθαρο γεωμετρικό πρότυπο (σχήμα ανεστραμμένου «V»). Αντίστοιχη μορφολογική μοναδικότητα παρουσιάζουν τα παπούτσια και οι τσάντες. Τα αντικείμενα που δεν ανήκουν στον άνω κορμό διαφέρουν ριζικά ως προς την τοπολογία τους, επιτρέποντας στο δίκτυο να τα διαχωρίσει με χαρακτηριστική ευκολία, χωρίς να απαιτείται η εξαγωγή σύνθετων μικροσκοπικών λεπτομερειών.

Αντιθέτως, ενδύματα όπως τα πουκάμισα, τα T-shirts και τα παλτά μοιράζονται μια σχεδόν πανομοιότυπη βασική σιλουέτα, καθώς είναι όλα σχεδιασμένα για να εφαρμόζουν στην ίδια ανατομική περιοχή του ανθρώπινου σώματος. Η εκτεταμένη αυτή γεωμετρική επικάλυψη καθιστά τον αλγόριθμο ιδιαίτερα επιρρεπή σε ταξινομικά σφάλματα.

Το πρόβλημα αυτό μεγεθύνεται και από τους εγγενείς περιορισμούς του ίδιου του Fashion-MNIST, το οποίο αποτελείται από εικόνες χαμηλής χωρικής ανάλυσης (28x28 pixels) αποκλειστικά σε κλίμακες του γκρι. Υπό αυτές τις συνθήκες, η οπτική πληροφορία συμπιέζεται σε τέτοιο βαθμό, ώστε η αναγνώριση λεπτών διαφορών στην υφή του υφάσματος —όπως, για παράδειγμα, η διάκριση μεταξύ ενός μάλλινου και ενός βαμβακερού υλικού— να καθίσταται πρακτικά αδύνατη για το δίκτυο.

Επομένως, είναι λογικό να αναμένουμε πάντα μία ελαφριά δυσλειτουργία στην ταξινόμηση ενδυμάτων άνω κορμού, ωστόσο αυτό δεν σημαίνει πως δεν μπορούμε να προτείνουμε θεωρητικές βελτιστοποιήσεις.

Σε περιπτώσεις όπου η ‘‘πρώτη όψη’’ μεταξύ δύο κλάσεων είναι πανομοιότυπη, η κατάλληλη ταξινόμηση κρίνεται στο πόσο καλά αναγνωρίζει το μοντέλο την βαθύτερη λεπτομέρεια (στο συγκεκριμένο παράδειγμα τον γιακά, τα κουμπιά, κ.ο.κ). Με άλλα λόγια, μια πρώτη προσέγγιση θα μπορούσε να είναι η προσθήκη επιπλέον συνελεκτιικών επιπέδων, ώστε οι μίκρο-ιδιαιτερότητες κάθε κλάσης να γίνονται πιο ευδιάκριτες στο μοντέλο. Κάτι τέτοιο βέβαια έρχεται με το ρίσκο της υπερεκπαίδευσης, παρόλα αυτά με κατάλληλες δοκιμές και συστηματικό πειραματισμό θα μπορούσε ενδεχομένως να βρεθεί μια μέση λύση η οποία να εξισορροπεί την πολυπλοκότητα και να επιστρέφει ακόμα καλύτερα αποτελέσματα.

Επεκτείνοντας αυτήν την σκέψη, θα μπορούσε να θεωρηθεί πως η αύξηση της πολυπλοκότητας είναι ουσιαστική μόνο στις περιπτώσεις ενδυμάτων άνω κορμού. Για τις υπόλοιπες, εύκολα αναγνωρίσιμες κλάσεις, η άσκοπη προσθήκη βαθύτερων επιπέδων θα εισήγαγε αδικαιολόγητο υπολογιστικό κόστος και θα αύξανε περιττά τον κίνδυνο υπερεκπαίδευσης (overfitting).

Η παρατήρηση αυτή οδηγεί με φυσικό τρόπο στην υιοθέτηση μιας επιπλέον στρατηγικής. Την **Ιεραρχική Ταξινόμησης (Hierarchical Classification)**. Η λογική της διασπάται σε δύο στάδια και είναι ιδιαίτερα απλή:

- Αρχικά, ένα πρώτο ρηχό συνελικτικό δίκτυο εκπαιδεύεται με αποκλειστικό σκοπό τον μακροσκοπικό διαχωρισμό των δεδομένων σε ευρείες, δομικά ευδιάκριτες κατηγορίες. "Παντελόνι", "Παπούτσι", "Τσάντα" και "Άνω κορμός" (ως μία ενιαία υπερ-κατηγορία).

- Εφόσον το πρώτο δίκτυο ταξινομήσει μια εικόνα στη συγκεκριμένη υπερ-κατηγορία "Άνω κορμός", το δείγμα προωθείται αυτόματα σε ένα δεύτερο, βαθύτερο και απόλυτα εξειδικευμένο δίκτυο. Το μοντέλο αυτό είναι εκπαιδευμένο αποκλειστικά στον εντοπισμό μικροσκοπικών λεπτομερειών για τον ακριβή διαχωρισμό μεταξύ παρεμφερών ενδυμάτων, όπως τα πουκάμισα, τα T-shirts και τα πουλόβερ.

Με αυτ;hν την προσέγγιση, η πολυπλοκότητα του δικτύου ρυθμίζεται δυναμικά, ανάλογα με την ιδιαιτερότητα του κάθε δείγματος στο σύνολο των δεδομένων.

Τέλος, αντί να ρυθμιστεί διαφορετικά η εκπαίδευση, μπορούμε να αλλάξουμε τον τρόπο με τον οποίο παρουσιάζουμε στο μοντέλο τα δεδομένα. Μία ανάλογη τεχνική που μπορεί ενδεχομένως να επιφέρει αποτελέσματα, είναι η **Επαύξηση Δεδομένων (Data Augmentation)**.

Όπως διαπιστώθηκε, η κύρια αιτία των σφαλμάτων στις ενδυμασίες άνω κορμού είναι η τάση του μοντέλου να βασίζεται υπερβολικά στην "τέλεια", κεντραρισμένη σιλουέτα των ρούχων, η οποία είναι πανομοιότυπη μεταξύ των προβληματικών κλάσεων. Εφαρμόζοντας τεχνικές επαύξησης κατά τη διάρκεια της εκπαίδευσης, εισάγουμε τεχνητά ελαφρές παραλλαγές στις εικόνες. Συγκεκριμένα:

- **Τυχαίες Περιστροφές (Rotations) και Μετατοπίσεις (Shifts):** Αλλοιώνουν την απόλυτη ευθυγράμμιση και τη θέση του ρούχου στο κάδρο.
- **Τυχαίες Μεγεθύνσεις (Zooming) και Οριζόντιες Αναστροφές (Horizontal Flips):** Μεταβάλλουν την κλίμακα και την προοπτική του αντικειμένου.

Με αυτόν τον τρόπο, καταστρέφεται η "ιδεατή" σιλουέτα πάνω στην οποία βασιζόταν το δίκτυο. Το μοντέλο αποθαρρύνεται από το να αποστηθίζει το γενικό περίγραμμα και εξαναγκάζεται να αναζητήσει πιο ανθεκτικά, εσωτερικά χαρακτηριστικά (όπως τοπικές συχνότητες pixels που ίσως υποδηλώνουν υφή ή γιακά) για να διαχωρίσει τις κλάσεις. Συνεπώς, η Επαύξηση Δεδομένων δεν αυξάνει απλώς τον όγκο των δεδομένων, αλλά ενισχύει ουσιαστικά την ικανότητα γενίκευσης του μοντέλου, καθιστώντας το πιο ανθεκτικό στις μορφολογικές επικαλύψεις.

5.1 Τελικά Συμπεράσματα

Στην τελική αξιολόγηση των αρχιτεκτονικών Βαθιάς Μάθησης στην οποία εξετάστηκαν τα δύο διαφορετικά σύνολα δεδομένων (MNIST και Fashion-

MNIST), καταλήξαμε σε τρία βασικά συμπεράσματα που συνδέονται στενά μεταξύ τους:

1. Ο θρίαμβος του CNN: Το CNN κέρδισε (συγκριτικά με το DNN) επειδή διατήρησε τις εικόνες στο φυσικό 2D πλέγμα τους. Χρησιμοποιώντας τοπικά φίλτρα χαρακτηριστικών, κατάφερε να μάθει πραγματικά σχήματα και χαρακτηριστικά, αντί να κάνει απλώς overfit (παπαγαλία) στα δεδομένα.
2. Η δυσκολία του Fashion-MNIST: Το Fashion-MNIST παρουσίασε πτώση στα ποσοστά απόδοσης και αυτό οφείλεται σε τρεις βασικούς λόγους:
    - Απλές Γραμμές vs. Συμπαγή Αντικείμενα: Εδώ είναι το μεγάλο πρόβλημα, όπου τα ψηφία του MNIST είναι απλές άσπρες γραμμές, ενώ τα ρούχα έχουν συμπαγή δομή, κουμπιά, υφές και μικρές λεπτομέρειες που το δίκτυο πρέπει πλέον να διαβάσει.
    - Μεγάλη Ομοιότητα: Ένα ακόμα πρόβλημα είναι ότι τα ρούχα έχουν μεγάλη ομοιότητα στο σχήμα μεταξύ τους (π.χ. ένα πουκάμισο με ένα πουλόβερ), σε αντίθεση με τα ψηφία όπου το ‘1’ διαφέρει αρκετά από το ‘2’ ή με το ‘8’ δεν μοιάζουν καθόλου.
    - Πολύ μικρές εικόνες: Σε μια ασπρόμαυρη και θολή εικόνα μόλις 28x28 pixels, χάνεται τεράστιος όγκος οπτικής πληροφορίας όταν προσπαθείς να απεικονίσεις ένα ολόκληρο παλτό ή ένα μποτάκι.
3. Το "παράδοξο" του Transfer Learning:
    - Το πρόβλημα της (Overfitting): Ένα δίκτυο που εκπαιδεύεται από το μηδέν μπορεί να βγάλει 98% στην εκπαίδευση, αλλά 88% στο τεστ. Αυτή η διαφορά (10%) δείχνει ξεκάθαρα ότι το δίκτυο δεν έμαθε πραγματικά, απλά απομνημόνευσε τα δεδομένα.
    - Του Transfer Learning: Όταν κάνεις Transfer Learning, "κλειδώνεις" την προϋπάρχουσα γνώση του δικτύου. Αυτό λειτουργεί σαν "εμπόδιο" (regularization) και του απαγορεύει να παπαγαλίσει τα νέα, πολύπλοκα δεδομένα (τα ρούχα).
    - Γιατί κερδίζει η Σταθερότητα: Επειδή του κόψαμε την ικανότητα να παπαγαλίζει, ο βαθμός του έπεσε στο 72%. Όμως, βγάζει το ίδιο ακριβώς 72% και στην εκπαίδευση και στο τεστ. Αυτή η μηδενική απόκλιση το κάνει απόλυτα αξιόπιστο για χρήση σε πραγματικές συνθήκες.

5.2 Μελλοντική Έρευνα (Και Περιορισμοί)

Δεδομένα Πραγματικού Κόσμου και Οπτική Αναζήτηση: Εμείς κάναμε ένα εργαστηριακό πείραμα με απλά, ασπόμαυρα ρούχα (Fashion-MNIST). Όμως, μια μελλοντική έρευνα με βάση τη σημερινή αγορά θα μπορούσε να γίνει με πιο σύγχρονα σύνολα δεδομένων, όπου τα δίκτυά μας θα εκπαιδεύονταν σε datasets με έγχρωμα ρούχα, όπως το DeepFashion Dataset. Έτσι, το CNN μοντέλο μας θα μπορούσε να χρησιμοποιηθεί σε πραγματικές εφαρμογές ηλεκτρονικού εμπορίου (E-commerce) για την Οπτική Αναζήτηση (Visual Search) και την αναγνώριση προϊόντων μέσω φωτογραφιών, όπως ακριβώς χρησιμοποιούν και προσπαθούν να εξελίξουν σήμερα μεγάλες εταιρείες όπως η Amazon και το Pinterest.

Αυτοματοποιημένη Διαλογή και Βιώσιμη Μόδα (Green AI): Μια άλλη σύγχρονη εφαρμογή της έρευνας μας βρίσκεται στον τομέα της βιώσιμης μόδας και της ανακύκλωσης ρούχων.

Είναι ένα από τα πιο "καυτά" θέματα αυτή τη στιγμή στη βιομηχανία, η διαδικασία που οι εταιρίες φτιάχνουν τα έξυπνα εργοστάσια διαλογής έχει ως εξής: Τα ρούχα τοποθετούνται πάνω στην Ταινία Μεταφοράς είναι ένας ιμάντας που περιστρέφει τα ρούχα με μεγάλη ταχύτητα, ακριβώς από πάνω υπάρχει η Κάμερα οπού βγάζει φωτογραφία το κάθε ρούχο που βρίσκεται πάνω στο ιμάντα. Η φωτογραφία του κάθε ρούχου περνάει από τον Εγκέφαλο CNN οπού το Συνεκτικό Νευρωνικό Δίκτυο αυτό παίρνει την φωτογραφία και τρέχει τα συντελεστικά του φίλτρα, ψάχνει να βρει λεπτομέρειες αν το ρούχο έχει μακριά μανίκια, φερμουάρ και γιακά. Η Απόφαση σε αυτό το στάδιο έχει πλέον βρει τι ρούχο είναι και σε ποια ακριβός κατηγορία θα μπει, Το Ρομπότ είναι αυτό που αφού γίνει η ταξινόμηση από το CNN θα βάλει το ρούχο στον σωστό κάδο ανακύκλωσης.